

人工智能

人工智能概述

主讲: 赵国亮

内蒙古大学电子信息工程学院

May 25, 2020

目录

- 1 不确定性推理
 - 统计概率的性质
- 2 证据理论
 - 主观 Bayes 方法
- 3 DS 理论的形式描述
 - 证据理论的推理模型
- 4 模糊推理

不精确性推理方法

现实世界中的大多数问题是不精确、非完备的.

对于这些问题, 若采用前面所讨论的精确性推理方法显然是无法解决的.

人工智能需要研究不精确性的推理方法, 以满足客观问题的需求.

不确定性推理的定义

什么是不确定性推理

- 不确定性推理泛指除精确推理以外的其它各种推理问题. 包括不完备、不精确知识的推理, 模糊知识的推理, 非单调性推理等.
- 不确定性推理过程实际上是一种从不确定的初始证据出发, 通过运用不确定性知识, 推出具有一定不确定性但却又是合理或基本合理的结论的思维过程.

为什么要采用不确定性推理

- 所需知识不完备.
- 不精确所需知识描述模糊.
- 多种原因导致同一结论.
- 问题的背景知识不足.
- 解题方案不唯一.

不确定性推理的基本问题

(1) 知识的不确定性的表示

- 考虑因素: 提高问题的描述能力, 处理推理中不确定性的计算.
- 含义: 知识的确定性程度, 或动态强度.
- 表示: 用概率 $[0,1]$, 0 接近于假, 1 接近于真. 用可信度 $[-1,1]$, 大于 0 接近于真, 小于 0 接近于假.

(2) 证据的非精确性表示

证据来源: 初始证据, 中间结论. 表示方式: 用概率、可信度或信任度.

- 含义

不确定的前提条件与不确定的事实匹配.

- 问题

前提是不确定的, 事实也是不确定的.

- 方法

设计一个计算相似程度的算法, 给出相似的限度.

- 标志

相似度落在规定限度内为匹配, 否则为不匹配.

4. ● 含义

知识的前提条件是多个证据的组合.

4. ● 方法

最大最小方法, 如合取取最小、析取取最大.
概率方法, 按概率.

4. 不精确性的更新

主要问题

- ① 如何用证据的不确定性去更新结论的不确定性.
- ② 如何在推理中把初始证据的不确定性传递给最终结论.

解决方法


4. 非精确性的更新

对① 不同推理方法的解决方法不同.

对② 不同推理方法的解决方法基本相同, 即把当前结论及其不确定性作为新的结论放入综合数据库, 依次传递, 直到得出最终结论.

非精确性结论的合成

含义: 多个不同知识推出同一结论, 且不确定性程度不同.
方法: 视不同推理方法而定.



主要介绍数值方法中的随机离散型概率的方法和离散论域上的模糊方法. 概率方法主要介绍 CF 理论和 DS 理论. 模糊方法主要介绍典型的模糊推理方法.

不确定性推理的概率论基础

在概率论中, 把试验中每一个可能出现的结果称为试验的一个样本点, 由全体样本点构成的集合称为样本空间.

表示: 通常用 Ω 表示样本空间, e 表示样本点.

概念: 由样本点构成的集合称为随机事件.

Example

1. 在掷币试验中, 若用 e_1 表示硬币的正面向上, 用 e_2 表示硬币的反面向上, 则该试验的样本空间为: $\Omega = \{e_1, e_2\}$.
2. 在掷币试验中, 若用 A 表示硬币正面向上这一事件, 则有 $A = \{e_1\}$.

概率运算

常见运算

- 并事件: 事件 A 与事件 B 至少有一个发生, 记为 $A \cup B$.
- 交事件: 事件 A 与事件 B 同时发生, 记为 $A \cap B$.
- 互逆事件: 事件 A 与 B 之间满足 “ $A \cap B = \emptyset, A \cup B = \Omega$ ” .

概率的统计定义

是通过某一事件出现的频率定义的. 频率:

$$f_n(A) = m/n, \quad (1)$$

式中, A 所讨论的事件, n 是试验的总次数, m 是实验中 A 发生的次数. 在同一组条件下所进行大量重复试验时, 如果事件 A 出现的频率总是在区间 $[0, 1]$ 上的一个确定常数 p 附近摆动, 并且稳定于 p , 则称 p 为事件 A 的统计概率. 即

$$P(A) = p. \quad (2)$$

Example

在掷币试验中, 当掷币次数足够多时有

$$f_n(\text{正面向上}) = 0.5. \quad (3)$$

则称正面向上的概率为 0.5, 即

$$P(\text{正面向上}) = 0.5. \quad (4)$$

概率的统计性质

性质

- (1) 对任一事件 A , 有 $0 \leq P(A) \leq 1$.
- (2) 必然事件 Ω 的概率 $P(\Omega) = 1$, 不可能事件 \emptyset 的概率 $P(\emptyset) = 0$.
- (3) 对任一事件 A , 有 $P(\neg A) = 1 - P(A)$.
- (4) 设事件 $A_1, A_2, \dots, A_k (k \leq n)$ 是两两互不相容的事件, 即有 $A_i \cap A_j = \emptyset (i \neq j)$, 则 $P(\sum_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$.
- (5) 设 A, B 是两个事件, 则 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

条件概率

条件概率

设 A 与 B 是两个随机事件, $P(B) > 0$, 则称:

$$P(A|B) = P(A \cap B)/P(B). \quad (5)$$

为在事件 B 发生的条件下事件 A 的条件概率.

Example

由于事件 B 已经发生, 因此以下事件 {取到红桃 A; 取到红桃 2; 取到红桃 3; ...; 取到红桃 K} 中必有一个出现.

而对事件 A, 在事件 B 发生的前提下, 只有以下事件 {取到红桃 J; 取到红桃 Q; 取到红桃 K 中的一个} 发生时事件 A 才能发生.

因此, 在事件 B 发生的条件下事件 A 发生的概率是 $3/13$.

全概率公式

设事件 A_1, A_2, \dots, A_n 满足:

- (1) 任意两个事件都互不相容, 即当 $i \neq j$ 时, 有 $A_i \cap A_j = \emptyset$, ($i = 1, 2, \dots, n$);
- (2) $P(A_i) > 0$ ($i = 1, 2, \dots, n$);
- (3) $\Omega = \bigcup_{n=1}^n A_n$, 则对任何事件 B 由下式成立:

$$P(B) = \sum_{i=1}^n P(A_i) \times P(B|A_i). \quad (6)$$

该公式称为**全概率公式**, 它提供了一种计算 $P(B)$ 的方法.

Bayes 定理

设事件 A_1, A_2, \dots, A_n 满足划分的条件, 则对任何事件 B 有下式成立:

$$P(A_i|B) = \frac{P(A_i) \times P(B/A_i)}{\sum_{j=1}^n P(A_j) \times P(B/A_j)}, i = 1, 2, \dots, n \quad (7)$$

该定理称为 **Bayes 定理**, 上式称为 Bayes 公式; 其中 $P(A_i)$ 是事件 A_i 的先验概率, $P(B|A_i)$ 是在事件 A_i 发生条件下事件 B 的条件概率; $P(A_i|B)$ 是在事件 B 发生条件下事件 A_i 的条件概率.

如果把全概率公式代入 Bayes 公式, 则有:

$$P(A_i|B) = \frac{P(A) \times P(B|A_i)}{P(B)}, i = 1, 2, \dots, n. \quad (8)$$

即

$$P(A_i|B) \times P(B) = P(B|A_i) \times P(A_i), i = 1, 2, \dots, n. \quad (9)$$

这是 Bayes 公式的另一种形式. Bayes 定理给出了用逆概率 $P(B|A_i)$ 求原概率 $P(A_i|B)$ 的方法.

可信度的概念

可信度

是指人们根据以往经验对某个事物或现象为真的程度的一个判断, 或者说是人们对某个事物或现象为真的相信程度.

例 2.1

沈强昨天没来上课, 理由是头疼. 就此理由, 只有以下两种可能:

- ♠ 一 是真的头疼了, 理由为真;
- ♠ 二 是没有头疼, 理由为假.

但就听话人而言, 因不能确切知道, 就只能某种程度上相信, 即可信度.



CF 模型

可信度具有一定的主观性, 较难把握. 但对某一特定领域, 让该领域专家给出可信度还是可行的.

知识不确定性的表示形式

在 CF 模型中, 知识是用产生式规则表示的, 其一般形式为:

IF E THEN H (CF(H, E)),

其中, E 是知识的前提条件; H 是知识的结论; CF(H, E) 是知识的可信度.

可信度的定义与性质

(1) E 可以是单一条件, 也可以是复合条件. 例如:

$$E = (E_1 \text{ OR } E_2) \text{ AND } E_3 \text{ AND } E_4.$$

(2) H 可以是单一结论, 也可以是多个结论

(3) CF 是知识的静态强度, $CF(H, E)$ 的取值为 $[-1, 1]$, 表示当 E 为真时, 证据对 H 的支持程度, 其值越大, 支持程度越大.

Example

IF 发烧 AND 流鼻涕 THEN 感冒 (0.8).

表示当某人确实有“发烧”及“流鼻涕”症状时, 则有 80% 的把握是患了感冒.

可信度的定义

在 CF 模型中, 把 $CF(H, E)$ 定义为

$$CF(H, E) = MB(H, E) - MD(H, E),$$

式中 MB 称为信任增长度, $MB(H, E)$ 定义为

$$MB(H, E) = \begin{cases} 1, & \text{若 } P(H) = 1 \\ \frac{\max\{P(H|E), P(H)\} - P(H)}{1 - P(H)}, & \text{否则} \end{cases} \quad (10)$$

MB 和 MD 的关系

MD 称为不信任增长度, $MD(H, E)$ 定义为

$$MD(H, E) = \begin{cases} 1, & \text{若 } P(H) = 0 \\ \frac{\min\{P(H|E), P(E)\} - P(H)}{1 - P(H)}, & \text{否则} \end{cases} \quad (11)$$

- ① 当 $MB(H, E) > 0$ 时, 有 $P(H|E) > P(H)$, 即 E 的出现增加了 H 的概率;
- ② 当 $MD(H, E) > 0$ 时, 有 $P(H|E) < P(H)$, 即 E 的出现降低了 H 的概率.

根据前面对 $CF(H, E)$ 可信度、 $MB(H, E)$ 信任增长度、 $MD(H, E)$ 不信任增长度的定义, 可得到 $CF(H, E)$ 的计算公式:

$$CF(H, E) = \begin{cases} MB(H, E) - 0 = \frac{P(H|E) - P(H)}{1 - P(H)} & \text{若 } P(H|E) > P(H) \\ 0 & \text{若 } P(H|E) = P(H) \\ 0 - MD(H, E) = -\frac{P(H) - P(H|E)}{P(H)} & \text{若 } P(H|E) < P(H) \end{cases} \quad (12)$$

分别由解释 $CF(H, E) > 0, CF(H, E) = 0, CF(H, E) < 0$.

可信度的性质

• 互斥性

对同一证据, 它不可能既增加对 H 的信任程度, 又同时增加对 H 的不信任程度, 这说明 MB 与 MD 是互斥的. 即有如下互斥性:

- 当 $MB(H, E) > 0$ 时, $MD(H, E) = 0$.
- 当 $MD(H, E) > 0$ 时, $MB(H, E) = 0$.

$$\begin{aligned}
 MD(\neg H, E) &= \frac{P(\neg H|E) - P(\neg H)}{-P(\neg H)} = \frac{(1 - P(H|E)) - (1 - P(H))}{-(1 - P(H))} \\
 &= \frac{-P(H|E) + P(H)}{-(1 - P(H))} = \frac{-(P(H|E) - P(H))}{-(1 - P(H))} \\
 &= \frac{P(H|E) - P(H)}{1 - P(H)} \\
 &= MB(H, E), \quad \text{信任增长度} \quad (13)
 \end{aligned}$$

再根据 CF 的定义和 MB、MD 的互斥性有

$$\begin{aligned} CF(H, E) + CF(\neg H, E) &= (MB(H, E) - MD(H, E)) + (MB(\neg H, E) - MD(\neg H, E)) \\ &= (MB(H, E) - 0) + (0 - MD(\neg H, E)), \quad (\text{由互斥性}) \\ &= MB(H, E) - MD(\neg H, E) = 0. \end{aligned}$$

说明

- (1) 对 H 的信任增长度等于对非 H 的不信任增长度.
- (2) 对 H 的可信度与非 H 的可信度之和等于 0.
- (3) 可信度不是概率, 不满足

$$CF(H) + CF(\neg H) = 1, 0 \leq CF(H), CF(\neg H) \leq 1.$$

(5) 对同一前提 E , 若支持若干个不同的结论 $H_i (i = 1, 2, \dots, n)$, 则如果发现专家给出的知识有如下情况

$$CF(H_1, E) = 0.7, CF(H_2, E) = 0.4.$$

则因 $0.7 + 0.4 = 1.1 > 1$ 为非法, 应进行调整或规范化.

证据不确定性的表示

不确定性的表示

证据的不确定性也是用可信度来表示的, 其取值范围也为 $[-1, 1]$.

- 若 E 为初始证据, 其值由用户给出.
- 若 E 为中间结论, 其值可通过计算得到.

可信度的含义

- $CF(E) = 1$, 证据 E 肯定它为真.
- $CF(E) = -1$, 证据 E 肯定它为假.
- $CF(E) = 0$, 对证据 E 一无所知.

否定证据不确定性的计算

- $0 < CF(E) < 1$, 证据 E 以 $CF(E)$ 程度为真.
- $-1 < CF(E) < 0$, 证据 E 以 $CF(E)$ 程度为假.

$$CF(\neg E) = -CF(E). \quad (14)$$

组合证据不确定性的计算

对证据的组合形式可分为“合取”与“析取”两种基本情况.

- 合取: 当组合证据是多个单一证据的组合时, 即 $E = E_1 \text{ AND } E_2 \text{ AND } \dots \text{ AND } E_n$ 时,

若已知 $CF(E_1), CF(E_2), \dots, CF(E_n)$, 则

$$CF(E) = \min\{CF(E_1), CF(E_2), \dots, CF(E_n)\}. \quad (15)$$

• 析取

当组合证据是多个单一证据的析取时, 即 $E = E_1 \text{ OR } E_2 \text{ OR } \dots \text{ OR } E_n$ 时, 若已知 $CF(E_1), CF(E_2), \dots, CF(E_n)$, 则

$$CF(E) = \max\{CF(E_1), CF(E_2), \dots, CF(E_n)\}. \quad (16)$$

CF 模型中的不确定性推理实际上是从不确定的初始证据出发, 不断运用相关的不确定性知识, 逐步推出最终结论和该结论可信度的过程.

不确定性的更新

每一次运用不确定性知识, 都需要由证据的不确定性和知识的不确定性去计算结论的不确定性.

不确定性的更新公式

$$CF(H) = CF(H, E) \times \max\{0, CF(E)\}. \quad (17)$$

若 $CF(E) < 0$, 则

$$CF(H) = 0, \quad (18)$$

即该模型没考虑 E 为假对 H 的影响.

若 $CF(E) = 1$, 则

$$CF(H) = CF(H, E), \quad (19)$$

即规则强度 $CF(H, E)$ 实际上是在 E 为真时, H 的可信度.

结论不确定性的合成

当有多条知识支持同一个结论, 且这些知识的前提相互独立, 结论的可信度又不相同时, 可利用不确定性的合成算法求出结论的综合可信度. 设有知识:

$$\text{IF } E_1 \text{ THEN } H \text{ (CF(H, } E_1)), \quad (20)$$

$$\text{IF } E_2 \text{ THEN } H \text{ (CF(H, } E_2)). \quad (21)$$

结论 H 的综合可信度可分以下两步计算

(1) 分别对每条知识求出其 $\text{CF}(H)$. 即

$$\text{CF}_1(H) = \text{CF}(H, E_1) \times \max\{0, \text{CF}(E_1)\}, \quad (22)$$

$$\text{CF}_2(H) = \text{CF}(H, E_2) \times \max\{0, \text{CF}(E_2)\}. \quad (23)$$

(2) 用如下公式求 E_1 与 E_2 对 H 的综合可信度

$$CF(H) = \begin{cases} CF_1(H) + CF_2(H) - CF_1(H) \times CF_2(H), & \text{若 } CF_1(H) \geq 0 \text{ 且 } CF_2(H) \geq 0 \\ CF_1(H) + CF_2(H) + CF_1(H) \times CF_2(H), & \text{若 } CF_1(H) < 0 \text{ 且 } CF_2(H) < 0 \\ \frac{CF_1(H) + CF_2(H)}{1 - \min\{|CF_1(H)|, |CF_2(H)|\}}, & \text{若 } CF_1(H) \text{ 与 } CF_2(H) \text{ 异号} \end{cases} \quad (24)$$

Example

设有如下一组知识:

- r_1 : IF E_1 THEN $H(0.9)$;
- r_2 : IF E_2 THEN $H(0.6)$;
- r_3 : IF E_3 THEN $H(-0.5)$;
- r_4 : IF E_4 AND (E_5 OR E_6) THEN $E_1(0.8)$.

已知: $CF(E_2) = 0.8$, $CF(E_3) = 0.6$, $CF(E_4) = 0.5$, $CF(E_5) = 0.6$, $CF(E_6) = 0.8$, 求 $CF(H)$.

一些典型值的含义

$A[0, 1]$: 说明对 A 一无所知. 其中, $\text{Bel}(A) = 0$, 说明对 A 无信任; 再由 $P_1(A) = 1 - \text{Bel}(\neg A) = 1$, 可知 $\text{Bel}(\neg A) = 0$, 说明对 $\neg A$ 也没有信任.

- $A[0, 0]$: 说明 A 为假. 即 $\text{Bel}(A) = 0, \text{Bel}(\neg A) = 1$.

- $A[1, 1]$: 说明 A 为真. 即 $\text{Bel}(A) = 1, \text{Bel}(\neg A) = 0$.

Example

设 $\Omega = \{a, b\}$, 且从不同知识源得到的概率分配函数分别为

$$m_1(\{\}, \{a\}, \{b\}, \{a, b\}) = (0, 0.3, 0.5, 0.2), \quad (63)$$

$$m_2(\{\}, \{a\}, \{b\}, \{a, b\}) = (0, 0.6, 0.3, 0.1). \quad (64)$$

求正交和 $m = m_1 \oplus m_2$.

先求 K

$$K = 1 - \sum_{x \cap y = \Phi} m_1(x) \times m_2(y) \quad (65)$$

$$= 1 - (m_1(\{a\}) \times m_2(\{b\}) + m_1(\{b\}) \times m_2(\{a\})) \quad (66)$$

$$= 1 - (0.3 \times 0.3 + 0.5 \times 0.6) = 0.61. \quad (67)$$

再求 $m(\{a\}, \{b\}, \{a, b\})$, 由于

$$\begin{aligned} m(\{a\}) &= \frac{1}{0.61} \times \sum_{x \cap y = \{a\}} m_1(x) \times m_2(y) \\ &= \frac{1}{0.61} \times (m_1(\{a\}) \times m_2(\{a\}) + m_1(\{a\}) \times m_2(\{a, b\}) + m_1(\{a, b\}) \times m_2(\{a\})) \\ &= \frac{1}{0.61} \times (0.3 \times 0.6 + 0.3 \times 0.1 + 0.2 \times 0.6) = \frac{33}{61} = 0.5410. \end{aligned} \quad (68)$$

同理可求得

$$m(\{b\}) = 0.43, \quad (69)$$

$$m(\{a, b\}) = 0.03. \quad (70)$$

故有

$$m(\{\}, \{a\}, \{b\}, \{a, b\}) = \{0, 0.54, 0.43, 0.03\}. \quad (71)$$

对于多个概率分配函数的组合, 方法类似.

$\text{Bel}(A)$ 和 $\text{Pl}(A)$ 分别表示命题 A 的信任度的下限和上限, 同时也可用来表示知识强度的下限和上限.

从信任函数和似然函数的定义看, 它们都是建立在概率分配函数之上的, 可见不同的概率分配函数将得到不同的推理模型.

- ① 只有当子集中的元素个数为 1 时, 其概率分配数才有可能大于 0;
- ② 当子集中有多个或 0 个元素, 且不等于全集时, 其概率分配数均为 0;
- ③ 全集 Ω 的概率分配数按 (3) 计算.

其似然函数

对任何命题 $A \subset \Omega$, 其似然函数为

$$\begin{aligned} P_l(A) &= 1 - \text{Bel}(\neg A) = 1 - \sum_{s_i \in \neg A} m(\{s_i\}) = 1 - \left[\sum_{i=1}^n m(\{s_i\}) - \sum_{s_i \in A} m(\{s_i\}) \right] \\ &= 1 - [1 - m(\Omega) - \text{Bel}(A)] \\ &= m(\Omega) + \text{Bel}(A). \end{aligned} \tag{75}$$

$$P_l(\Omega) = 1 - \text{Bel}(\neg \Omega) = 1 - \text{Bel}(\Phi) = 1. \tag{76}$$

可以看出, 对任意命题 $A \subset \Omega$ 和 $B \subset \Omega$ 均有:

$$P_l(A) - \text{Bel}(A) = P_l(B) - \text{Bel}(B) = m(\Omega). \tag{77}$$

它表示对 A (或 B) 不知道的程度.

基本概率分配函数的正交和

设 m_1 和 m_2 是 2^Ω 上的基本概率分配函数, 它们的正交和定义为

$$m(\{s_i\}) = K^{-1} \times [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \quad (82)$$

Example

设 $\Omega = \{\text{红}, \text{黄}, \text{白}\}$, 概率分配函数

$$m(\{\}, \{\text{红}\}, \{\text{黄}\}, \{\text{白}\}, \{\text{红}, \text{黄}, \text{白}\}) = (0, 0.6, 0.2, 0.1, 0.1). \quad (83)$$

$A = \{\text{红}, \text{黄}\}$, 求 $m(\Omega)$, $\text{Bel}(A)$ 和 $P_l(A)$ 的值.

$$\begin{aligned} m(\Omega) &= 1 - [m(\{\text{红}\}) + m(\{\text{黄}\}) + m(\{\text{白}\})] \\ &= 1 - (0.6 + 0.2 + 0.1) = 0.1. \end{aligned} \quad (84)$$

$$\text{Bel}(\{\text{红}, \text{黄}\}) = m(\{\text{红}\}) + m(\{\text{黄}\}) = 0.6 + 0.2 = 0.8. \quad (85)$$

$$P_1(\{\text{红}, \text{黄}\}) = m(\Omega) + \text{Bel}(\{\text{红}, \text{黄}\}) = 0.1 + 0.8 = 0.9. \quad (86)$$

另一形式

$$P_1(\{\text{红}, \text{黄}\}) = 1 - \text{Bel}(\neg\{\text{红}, \text{黄}\}) = 1 - \text{Bel}(\text{白}) = 1 - 0.1 = 0.9. \quad (87)$$

概率分配函数的正交和

设 m_1 和 m_2 是 2^Ω 上的基本概率分配函数, 分配函数的正交和定义为

$$m(\{s_i\}) = K^{-1} \times [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \quad (88)$$

其中,

$$K = m_1(\Omega) \times m_2(\Omega) + \sum_{i=1}^n [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \quad (89)$$

类概率函数

设 Ω 为有限域, 对任何命题 $A \subset \Omega$, 命题 A 的类概率函数为

$$f(A) = \text{Bel}(A) + \frac{|A|}{|\Omega|} \times [P_1(A) - \text{Bel}(A)], \quad (90)$$

其中, $|A|$ 和 $|\Omega|$ 分别是 A 及 Ω 中元素的个数.

类概率函数 $f(A)$ 的性质

$$(1) \sum_{i=1}^n f(\{s_i\}) = 1, s_i \in \Omega.$$

$$\because f(\{s_i\}) = \text{Bel}(\{s_i\}) + \frac{|\{s_i\}|}{|\Omega|} \times [\text{Pl}(\{s_i\}) - \text{Bel}(\{S_i\})]$$

$$= m(\{s_i\}) + \frac{1}{n} \times m(\Omega), i = 1, 2, \dots, n.$$

$$\therefore \sum_{i=1}^n f(\{s_i\}) = \sum_{i=1}^n \left[m(s_i) + \frac{1}{n} \times m(\Omega) \right] \quad (91)$$

$$= \sum_{i=1}^n m(\{s_i\}) + m(\Omega) = 1.$$

(2) 对任何 $A \subset \Omega$, 有 $\text{Bel}(A) \leq f(A) \leq P_l(A)$.

$$\begin{aligned} \because P_l(A) - P_l(B) &= m(\Omega), \quad \frac{|A|}{|\Omega|} \geq 0 \\ \therefore \text{Bel}(A) &\leq f(A) \\ \because \frac{|A|}{|\Omega|} &\leq 1, f(A) \leq \text{Bel}(A) + P_l(A) - \text{Bel}(A), \\ \therefore f(A) &\leq P_l(A). \end{aligned} \tag{92}$$

(3) 对任何 $A \subseteq \Omega$, 有 $f(\neg A) = 1 - f(A)$.

$$\therefore f(\neg A) = \text{Bel}(\neg A) + \frac{|A|}{|P_1(\neg A) - \text{Bel}(\neg A)|} \quad (93)$$

$$\begin{aligned} \text{Bel}(\neg A) &= \sum_{\substack{s \in \neg A \\ s \in \Omega}} m(\{s_i\}) \\ &= 1 - \sum_{s_i \in A} m(\{s_i\}) - m(\Omega) = 1 - \text{Bel}(A) - m(\Omega). \end{aligned} \quad (94)$$

$$|\neg A| = |\Omega| - |A|. \quad (95)$$

$$m(\Omega) = P_1(\neg A) - \text{Bel}(\neg A). \quad (96)$$

$$\begin{aligned}
 \therefore f(\neg A) &= 1 - \text{Bel}(A) - m(\Omega) + \frac{|\Omega| - |A|}{|\Omega|} \times m(\Omega) \\
 &= 1 - \text{Bel}(A) - m(\Omega) + m(\Omega) - \frac{|A|}{|\Omega|} \times m(\Omega) \\
 &= 1 - \left[\text{Bel}(A) + \frac{|A|}{|\Omega|} \times m(\Omega) \right] = 1 - f(A). \quad (97)
 \end{aligned}$$

推论

- (1) $f(\emptyset) = 0$;
- (2) $f(\Omega) = 1$;
- (3) 对任何 $A \subseteq \Omega$, 有 $0 \leq f(A) \leq 1$.

Example

设 $\Omega = \{\text{红}, \text{黄}, \text{白}\}$, 概率分配函数

$$m(\{\}, \{\text{红}\}, \{\text{黄}\}, \{\text{白}\}, \{\text{红}, \text{黄}, \text{白}\}) = (0, 0.6, 0.2, 0.1, 0.1). \quad (98)$$

若 $A = \{\text{红}, \text{黄}\}$, 求 $f(A)$ 的值.

$$\begin{aligned}
 f(A) &= \text{Bel}(A) + \frac{|A|}{|\Omega|} \times [P_1(A) - \text{Bel}(A)] \\
 &= m(\{\text{红}\}) + m(\{\text{黄}\}) + \frac{2}{3} \times (1 - \text{Bel}(\neg A) - 0.8) \quad (99) \\
 &= 0.6 + 0.2 + \frac{2}{3} \times 0.1 = 0.87.
 \end{aligned}$$

表示形式

$$\text{IF } E \text{ THEN } H = \{h_1, h_2, \dots, h_n\} \text{ CF} = \{c_1, c_2, \dots, c_n\}. \quad (100)$$

其中:

- E 为前提条件, 它既可以是简单条件, 也可以是用合取或析取词连接起来的复合条件;
- H 是结论, 它用样本空间中的子集表示, h_1, h_2, \dots, h_n 是该子集中的元素;
- CF 是可信度因子, 用集合形式表示. 该集合中的元素 c_1, c_2, \dots, c_n 用来指出 h_1, h_2, \dots, h_n 的可信度, c_i 与 h_i 一一对应. 并且 c_i 应满足如下条件:

$$c_i \geq 0, \sum_{i=1}^n c_i \leq 1, i = 1, 2, \dots, n. \quad (101)$$

Example

设 A 是规则条件部分的命题, E' 是外部输入的证据和已证实的命题, 在证据 E' 的条件下, 命题 A 与证据 E' 的匹配程度为

$$MD(A|E') = \begin{cases} 1, & \text{如果H所要求的证据都已出现} \\ 0, & \text{否则} \end{cases} \quad (102)$$

条件部分命题 A 的确定性

$$\text{CER}(A) = \text{MD}(A|E') \times f(A), \quad (103)$$

其中 $f(A)$ 为类概率函数. 由于 $f(A) \in [0, 1]$, 因此 $\text{CER}(A) \in [0, 1]$.

♠ 当组合证据是多个证据的合取时:

$$E = E_1 \text{ AND } E_2 \text{ AND } \cdots \text{ AND } E_n. \quad (104)$$

则

$$\text{CER}(E) = \min\{\text{CER}(E_1), \text{CER}(E_2), \cdots, \text{CER}(E_n)\}. \quad (105)$$

♠ 当组合证据是多个证据的析取时:

$$E = E_1 \text{ OR } E_2 \text{ OR } \cdots \text{ OR } E_n. \quad (106)$$

则

$$\text{CER}(E) = \max\{\text{CER}(E_1), \text{CER}(E_2), \cdots, \text{CER}(E_n)\}. \quad (107)$$

设有知识 IF E THEN $H = \{h_1, h_2, \dots, h_n\}$ $CF = \{c_1, c_2, \dots, c_n\}$, 则求结论 H 的确定性 $CER(H)$ 的方法如下:

(1) 求 H 的概率分配函数

$$m(\{h_1\}, \{h_2\}, \dots, \{h_3\}) = (CER(E) \times c_1, CER(E) \times c_2, \dots, CER(E) \times c_n) \quad (108)$$

$$m(\Omega) = 1 - \sum_{i=1}^n CRE(E) \times c_i. \quad (109)$$

如果有两条或多条知识支持同一结论 H , 例:

$$\text{IF } E \text{ THEN } H = \{h_1, h_2, \dots, h_n\} \quad CF = \{c_{11}, c_{12}, \dots, c_{1n}\}, \quad (110)$$

$$\text{IF } F \text{ THEN } H = \{h_1, h_2, \dots, h_n\} \quad CF = \{c_{21}, c_{22}, \dots, c_{2n}\}. \quad (111)$$

则按正交和求 $CER(H)$, 即先求出:

$$m_1 = m(h_1, h_2, \dots, h_n), \quad (112)$$

$$m_2 = m(h_1, h_2, \dots, h_n). \quad (113)$$

然后再用公式 $m = m_1 \oplus m_2$ 求 m_1 和 m_2 的正交和, 最后求得 H 的 m .

(2) 求 $\text{Bel}(H)$ 、 $P_1(H)$ 及 $f(H)$

$$\begin{aligned} \text{Bel}(H) &= \sum_{i=1}^n m(\{h_i\}), \\ P_1(H) &= 1 - \text{Bel}(\neg H), \\ f(H) &= \text{Be}(H) + \frac{|H|}{|\Omega|} \times [P_1(H) - \text{Be}(H)] = \text{Be}(H) + \frac{|H|}{|\Omega|} \times m(\Omega). \end{aligned} \quad (114)$$

(3) 求 H 的确定性 $\text{CER}(H)$

按公式 $\text{CER}(H) = \text{MD}(H|E') \times f(H)$ 计算结论 H 确定性.

Example

设有如下规则:

- r_1 : IF E_1 AND E_2 THEN $A=\{a_1, a_2\}$ $CF=\{0.3, 0.5\}$,
- r_2 : IF E_3 AND (E_4 OR E_5) THEN $B=\{b_1\}$ $CF=\{0.7\}$,
- r_3 : IF A THEN $H=\{h_1, h_2, h_3\}$ $CF=\{0.1, 0.5, 0.3\}$,
- r_4 : IF B THEN $H=\{h_1, h_2, h_3\}$ $CF=\{0.4, 0.2, 0.1\}$.

已知用户对初始证据给出的确定性为:

$$CER(E_1)=0.8, CER(E_2)=0.6, CER(E_3)=0.9, CER(E_4)=0.5, CER(E_5)=0.7.$$

并假定 Ω 中的元素个数 $|\Omega| = 10$, 求 $CER(H)$.

由给定知识形成的推理网络为:




图 1: 给定知识形成的推理网络

(1) 求 CER(A)

$$\therefore \text{CER}(E_1 \text{ AND } E_2) = \min\{\text{CER}(E_1), \text{CER}(E_2)\} = \min\{0.8, 0.6\} = 0.6.$$

$$m(\{a_1, a_2\}) = \{0.6 \times 0.3, 0.6 \times 0.5\} = \{0.18, 0.3\}.$$

$$\text{Bel}(A) = m(a_1) + m(a_2) = 0.18 + 0.3 = 0.48.$$

$$P_1(A) = 1 - \text{Bel}(\neg A) = 1 - 0 = 1.$$

$$\begin{aligned} f(A) &= \text{Bel}(A) + |A|/|\Omega| * [P_1(A) - \text{Bel}(A)] \\ &= 0.48 + 2/10 * [1 - 0.48] = 0.584. \end{aligned}$$

$$\therefore \text{CER}(A) = \text{MD}(A|E') \times f(A) = 0.584.$$

(2) 求 CER(B)

$$\begin{aligned}\therefore \text{CER}(E_3 \text{ AND } (E_4 \text{ OR } E_5)) &= \min\{\text{CER}(E_3), \max\{\text{CER}(E_4), \text{CER}(E_5)\}\} \\ &= \min\{0.9, \max\{0.5, 0.7\}\} \\ &= \min\{0.9, 0.7\} = 0.7.\end{aligned}$$

$$m(b_1) = 0.7 \times 0.7 = 0.49.$$

$$\text{Bel}(B) = m(b_1) = 0.49.$$

$$\text{Pl}(B) = 1 - \text{Bel}(\neg B) = 1 - 0 = 1.$$

$$\begin{aligned}F(B) &= \text{Bel}(B) + |B|/|\Omega| * [\text{Pl}(B) - \text{Bel}(B)] \\ &= 0.49 + 1/10 * [1 - 0.49] = 0.541.\end{aligned}$$

$$\therefore \text{CER}(B) = \text{MD}(B|E') \times f(B) = 0.541.$$

(3) 求 $CER(H)$, 由 r_3 可得

$$\begin{aligned} m_1(h_1, h_2, h_3) &= \{CER(A) \times 0.1, CER(A) \times 0.5, CER(A) \times 0.3\} \\ &= \{0.584 \times 0.1, 0.584 \times 0.5, 0.584 \times 0.3\} \\ &= \{0.058, 0.292, 0.175\}. \end{aligned}$$

$$\begin{aligned} m_1(\Omega) &= 1 - [m_1(h_1) + m_1(h_2) + m_1(h_3)] \\ &= 1 - (0.058 + 0.292 + 0.175) = 0.475. \end{aligned}$$

再由 r_4 可得

$$\begin{aligned} m_2(h_1, h_2, h_3) &= \{CER(B) \times 0.4, CER(B) \times 0.2, CER(B) \times 0.1\} \\ &= \{0.541 \times 0.4, 0.541 \times 0.2, 0.541 \times 0.1\} \\ &= \{0.216, 0.108, 0.054\}. \\ m_2(\Omega) &= 1 - [m_2(h_1) + m_2(h_2) + m_2(h_3)] \\ &= 1 - [0.216 + 0.108 + 0.054] = 0.622. \end{aligned}$$

求正交和 $m = m_1 \oplus m_2$

$$\begin{aligned}
 K &= m_1(\Omega) \times m_2(\Omega) + m_1(h_1) \times m_2(h_1) + m_1(h_1) \times m_2(\Omega) + m_1(\Omega) \times m_2(h_1) \\
 &\quad + m_1(h_2) \times m_2(h_2) + m_1(h_2) \times m_2(\Omega) + m_1(\Omega) \times m_2(h_2) \\
 &\quad + m_1(h_3) \times m_2(h_3) + m_1(h_3) \times m_2(\Omega) + m_1(\Omega) \times m_2(h_3) \\
 &= 0.475 \times 0.622 + 0.058 \times 0.216 + 0.058 \times 0.622 + 0.475 \times 0.216 \\
 &\quad + 0.292 \times 0.108 + 0.292 \times 0.622 + 0.475 \times 0.108 \\
 &\quad + 0.175 \times 0.054 + 0.175 \times 0.622 + 0.475 \times 0.054 = 0.855.
 \end{aligned}$$

$$\begin{aligned} m(h_1) &= \frac{1}{K} \times [m_1(\{h_1\}) \times m_2(\{h_1\}) + m_1(\{h_1\}) \times m_2(\Omega) + m_1(\Omega) \times m_2(\{h_1\})] \\ &= \frac{1}{0.855} \times [0.058 \times 0.216 + 0.058 \times 0.622 + 0.475 \times 0.216]. \end{aligned}$$

$$\begin{aligned} m(h_2) &= \frac{1}{K} \times [m_1(\{h_2\}) \times m_2(\{h_2\}) + m_1(\{h_2\}) \times m_2(\Omega) + m_1(\Omega) \times m_2(\{h_2\})] \\ &= \frac{1}{0.855} \times [0.292 \times 0.108 + 0.292 \times 0.622 + 0.475 \times 0.108] \\ &= 0.309. \end{aligned}$$

$$\begin{aligned} m(h_3) &= \frac{1}{K} \times [m_1(\{h_3\}) \times m_2(\{h_3\}) + m_1(\{h_3\}) \times m_2(\Omega) + m_1(\Omega) \times m_2(\{h_3\})] \\ &= \frac{1}{0.855} \times [0.175 \times 0.054 + 0.175 \times 0.622 + 0.475 \times 0.054] \\ &= 0.168. \end{aligned}$$

$$m(\Omega) = 1 - [m(h_1) + m(h_2) + m(h_3)] = 1 - (0.178 + 0.309 + 0.168) = 0.345.$$

$$\text{Bel}(H) = m(h_1) + m(h_2) + m(h_3) = 0.178 + 0.309 + 0.168 = 0.655$$

$$P_l(H) = m(\Omega) + \text{Bel}(H) = 0.345 + 0.655 = 1.$$

$$\begin{aligned} f(H) &= \text{Bel}(H) + \frac{|H|}{|\Omega|} \times [P_l(H) - \text{Bel}(H)]. \\ &= 0.655 + \frac{3}{10} \times [1 - 0.655] \\ &= 0.759. \end{aligned}$$

$$\text{CER}(H) = \text{MD}(H|E') \times f(H) = 0.759.$$

DS 理论的优缺点

优点

能处理由“不知道”所引起的非精确性; 并且由于辨别框 (样本空间) 的子集可以是多个元素的集合, 这样更有利于领域专家在不同层次上进行知识表示.

缺点

要求辨别框中的元素满足互斥条件, 这在实际系统中不易实现; 并且, 需要给出的概率分配数太多, 计算比较复杂.

模糊推理表示

模糊推理表示用自然语言中的词或句子表示的变量.

Example

变量“年龄”在普通集合中为数字变量 $u = [0, 150]$, 而在模糊集和中可使用语言变量, 该语言变量的取值可以是年轻、很年轻、不很年轻、老、很老、不很老等. 这些值可看作是论域 $U = [0, 150]$ 上模糊集的集合名.

模糊谓词

模糊谓词

设 $x \in U$, F 为模糊谓词, 即 U 中的一个模糊关系, 则模糊命题可表示为

$$x \text{ is } F, \quad (115)$$

其中的模糊谓词 F 可以是 大、小、年轻、年老、冷、暖、长、短等.

模糊量词

模糊量词

模糊逻辑中使用的模糊量词, 如极少、很少、几个、少数、多数、大多数、几乎所有等. 这些模糊量词可以很方便地描述类似于下面的命题:

- 大多数成绩好的学生学习都很刻苦.
- 很少有成绩好的学生特别贪玩.

模糊概率、模糊可能性和模糊真值

设 λ 为模糊概率, Π 为模糊可能性, τ 为模糊真值, 则对命题还可以附加概率限定、可能性限定和真值限定:

$$(x \text{ is } F) \text{ is } \lambda(x \text{ is } F) \text{ is } \Pi(x \text{ is } F) \text{ is } \tau, \quad (116)$$

其中, λ 可以是“或许”、“必须”等; π 可以是“非常可能”、“很不可能”等; τ 可以是“非常真”、“有些假”等.

Example

“常青很可能是年轻的” 可表示为

(Age(Chang qing) is young) is likely.

模糊修饰语的表达

模糊修饰语

设 m 是模糊修饰语, x 是变量, F 谓模糊谓词, 则模糊命题可表示为 x is m_F , 模糊修饰语也称为程度词, 常用的程度词有“很”、“非常”、“有些”、“绝对”等.

主要通过以下四种运算实现

① 求补: \neg 表示否定, 如“不”、“非”等, 其隶属函数的表示为

$$\mu_{\neg F}(u) = 1 - \mu_F(u) \quad u \in [0, 1].$$

② 集中表示“很”、“非常”等, 其效果是减少隶属函数的值:

$$\mu_{\text{非常}F}(u) = \mu_F^2(u) \quad u \in [0, 1].$$

③ 扩张表示“有些”、“稍微”等, 其效果是增加隶属函数的值:

$$\mu_{\text{有些}F}(u) = \mu_F^{\frac{1}{2}}(u) \quad u \in [0, 1].$$

④ 加强对比表示“明确”、“确定”等, 其效果是增加 0.5 以上隶属函数的值, 减少 0.5 以下隶属函数的值:

$$\mu_{\text{确实}F}(u) = \begin{cases} 2\mu_F^2(u), & 0 \leq \mu_F(u) \leq 0.5 \\ 1 - 2(1 - \mu_F(u))^2, & 0.5 < \mu_F(u) \leq 1 \end{cases} .$$

在以上 4 种运算中, 集中与扩张用的较多.

语言变量“真实性”取值“真”和“假”的隶属函数

$$\begin{aligned}\mu_{\text{真}}(u) &= u, & u &\in [0, 1] \\ \mu_{\text{假}}(u) &= 1 - u, & u &\in [0, 1].\end{aligned}$$

则“非常真”、“有些真”、“非常假”、“有些假”可定义为

$$\mu_{\text{非常真}}(u) = u^2, u \in [0, 1]; \mu_{\text{非常假}}(u) = (1 - u)^2, u \in [0, 1]; \quad (117)$$

$$\mu_{\text{有些真}}(u) = u^{\frac{1}{2}}, u \in [0, 1]; \mu_{\text{有些假}}(u) = (1 - u)^{\frac{1}{2}}, u \in [0, 1]. \quad (118)$$

扎德推理模型——产生式规则的表示形式是

IF x is F THEN y is G .

其中: x 和 y 是变量, 表示对象; F 和 G 分别是论域 U 和 V 上的模糊集, 表示概念.

语义距离

用于刻画两个模糊概念之间的差异. 一般使用的距离是海明距离.

离散论域: 设 $U = u_1, u_2, \dots, u_n$ 是一个离散有限论域, F 和 G 分别是论域 U 上的两个模糊概念的模糊集, 则 F 和 G 的海明距离定义为

$$d(F, G) = \frac{1}{n} \times \sum_{i=1}^n |\mu_F(u_i) - \mu_G(u_i)|. \quad (119)$$

连续论域

如果论域 U 是实数域上的某个闭区间 $[a, b]$, 则海明距离为

$$d(F, G) = \frac{1}{b-a} \int_a^b |\mu_F(u) - \mu_G(u)| d(u). \quad (120)$$

Example

设论域 $U = \{-10, 0, 10, 20, 30\}$ 表示温度, 模糊集

$$F = 0.8/-10 + 0.5/0 + 0.1/10, \quad (121)$$

$$G = 0.9/-10 + 0.6/0 + 0.2/10. \quad (122)$$

分别表示“冷”和“比较冷”, 则

$$d(F, G) = 0.2 \times (|0.8 - 0.9| + |0.5 - 0.6| + |0.1 - 0.2|) = 0.2 \times 0.3 = 0.06. \quad (123)$$

即 F 和 G 的海明距离为 0.06.

设 F 和 G 分别是论域 $U = \{u_1, u_2, \dots, u_n\}$ 上的两个模糊概念的模糊集, 则它们的贴近度定义为

$$(F, G) = (1/2)(F \cdot G + (1 - F \odot G)), \quad (124)$$

其中:

$$\begin{aligned} F \cdot G &= \bigvee (\mu_F(u_i) \wedge \mu_G(u_i)), \\ F \odot G &= \bigwedge_U (\mu_F(u_i) \vee \mu_G(u_i)). \end{aligned} \quad (125)$$

称 $F \cdot G$ 为内积, $F \odot G$ 为外积.

Example

设论域 U 及其上的模糊集 F 和 G 如上例所示, 则

$$\begin{aligned} F \cdot G &= 0.8 \wedge 0.9 \vee 0.5 \wedge 0.6 \vee 0.1 \wedge 0.2 \vee 0 \wedge 0 \vee 0 \wedge 0 \\ &= 0.8 \vee 0.5 \vee 0.1 \vee 0 \vee 0 = 0.8 \end{aligned}$$

$$\begin{aligned} F \odot G &= (0.8 \vee 0.9) \wedge (0.5 \vee 0.6) \wedge (0.1 \vee 0.2) \wedge (0 \vee 0) \wedge (0 \vee 0) \\ &= 0.9 \wedge 0.6 \wedge 0.2 \wedge 0 \wedge 0 = 0 \end{aligned}$$

$$(F, G) = 0.5 \times (0.8 + (1 - 0)) = 0.5 \times 1.8 = 0.9.$$

即 F 和 G 的贴度为 0.9.

模糊推理及其构造

模糊推理实际上是按照给定的推理模式, 通过模糊集合与模糊关系的合成来实现的.

模糊关系 R_m

R_m 是由扎德提出的一种构造模糊关系的方法. 设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_m 定义为

$$R_m = \int_{U \times V} (\mu_F(u) \wedge \mu_G(v)) \vee (1 - \mu_F(u)) / (u, v), \quad (126)$$

其中, \times 号表示模糊集的笛卡尔乘积.

Example

设 $U = V = \{1, 2, 3\}$, F 和 G 分别是 U 和 V 上的两个模糊集, 且
 $F = 1/1 + 0.6/2 + 0.1/3$, $G = 0.1/1 + 0.6/2 + 1/3$, 求 $U \times V$ 上的 R_m .

$$R_m = \int_{U \times V} (\mu_F(u) \wedge \mu_G(v)) \vee (1 - \mu_F(u)) / (u, v).$$

$$R_m = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.4 & 0.6 & 0.6 \\ 0.9 & 0.9 & 0.9 \end{bmatrix}.$$

如: $R_m(2, 3) = (0.6 \wedge 1) \vee (1 - 0.6) = 0.6 \vee 0.4 = 0.6$.

模糊关系 R_c

R_c 是由麦姆德尼 (Mamdani) 提出的一种构造模糊关系的方法.

设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_c 义为

$$R_c = \int_{U \times V} (\mu_F(u) \wedge \mu_G(v))_Q / (u, v).$$

Example

对例 18 所给出的模糊集

$$\mathbf{F} = 1/1 + 0.6/2 + 0.1/3, \mathbf{G} = 0.1/1 + 0.6/2 + 1/3.$$

其 R_c 为

$$R_c = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix},$$

如 $R_c(3, 2)$: $R_c(3, 2) = \mu_F(u_3) \wedge \mu_G(v_2) = 0.1 \wedge 0.6 = 0.1.$

模糊关系 R_g

R_g 是米祖莫托 (Mizumoto) 提出的一种构造模糊关系的方法.

设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_g 定义为

$$R_g = \int_{U \times V} (\mu_F(u) \rightarrow \mu_G(v)) / (u, v),$$

其中

$$\mu_F(u) \rightarrow \mu_G(v) = \begin{cases} 1, & \mu_F(u) \leq \mu_G(v) \\ \mu_G(v), & \mu_F(u) > \mu_G(v) \end{cases}.$$

Example

对例 18 所给出的模糊集

$$\mathbf{F} = 1/1 + 0.6/2 + 0.1/3, \mathbf{G} = 0.1/1 + 0.6/2 + 1/3.$$

其 R_g 为

$$R_g = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

设 F 和 G 分别是 U 和 V 上的两个模糊集, 且有知识

知识： IF x is F THEN y is G.

若有 U 上的一个模糊集 F' , 且 F 可以和 F' 匹配, 则可以推出 y is G' , 且 G' 是 V 上的一个模糊集. 这种推理模式称为模糊假言推理, 其表示形式为:

知识： IF x is F THEN y is G

证据: IF x is F'

结论： THEN y is G'

在这种推理模式下, 模糊知识

IF x is F THEN y is G.

表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R. 则有

$$G' = F' \circ R,$$

其中的模糊关系 R, 可以是 R_m 、 R_c 或 R_g 中的任何一种.

模糊推理的基本方法

Example

对例 18 所给出的 F 、 G , 以及所求出的 R_m , 设有已知事实: $\{x \text{ is 较小}\}$, 并设“较小”的模糊集为: $\text{较小} = 1/1 + 0.7/2 + 0.2/3$, 求在此已知事实下的模糊结论.

例 18 的模糊关系 R_m 已在例 18 中求出, 设已知模糊事实“较小”为 F' , F' 与 R_m 的合成即为所求结论 G' .

$$G' = F' \circ R_m = \{1, 0.7, 0.2\} \circ \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.4 & 0.6 & 0.6 \\ 0.9 & 0.9 & 0.9 \end{bmatrix} = \{0.4, 0.6, 1\}.$$

即所求出的模糊结论 G' 为 $G' = 0.4/1 + 0.6/2 + 1/3$.

模糊拒取式推理

设 F 和 G 分别是 U 和 V 上的两个模糊集, 且有知识

IF x is F THEN y is G .

若有 V 上的一个模糊集 G' , 且 G 可以和 G' 匹配, 则可以推出 x is F' , 且 F' 是 U 上的一个模糊集.

模糊拒取式推理

其表示形式为:

知识 : IF x is F THEN y is G.

证据 : THEN z is H.

— — — — —

结论 : IF x is F'.

在这种推理模式下, 模糊知识

IF x is F THEN y is G.

也表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R, 则有 $F' = R \circ G'$, 其中的模糊关系 R, 可以是 R_m 、 R_c 或 R_g 中的任何一种.

Example

设 F 和 G 如例 18 所示, 已知事实为 {y is 较大}, 且“较大”的模糊集为: 较大 = $0.2/1 + 0.7/2 + 1/3$, 若已知事实与 G 匹配, 以模糊关系 R_c 为例, 在此已知事实下可以推出 F' .

本例的模糊关系 R_c 已在前面求出, 设模糊概念“较大”为 G' , 则 R_c 与 G' 的合成即为所求的 F' .

$$F' = R_c \circ G' = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix} \circ \begin{bmatrix} 0.2 \\ 0.7 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.6 \\ 0.1 \end{bmatrix}.$$

即所求出的 F' 为 $G' = 1/1 + 0.6/2 + 0.1/3$.

模糊假言三段论推理

设 F, G, H 分别是 U, V, W 上的 3 个模糊集, 且由知识

IF x is F THEN y is G ,
IF y is G THEN z is H .

则可推出:

IF x is F THEN z is H .

模糊假言三段论推理

它可表示为:

IF x is F THEN y is G
IF y is G THEN z is H
—— — — — —
IF x is F THEN z is H.

在模糊假言三段论推理模式下, 模糊知识

$r_1 : \text{IF } x \text{ is } F \text{ THEN } y \text{ is } G,$

表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R_1 .

模糊知识

$r_2 : \text{IF } y \text{ is } G \text{ THEN } z \text{ is } H,$

表示在 G 与 H 之间存在着确定的因果关系, 设此因果关系为 R_2 .
若模糊假言三段论成立, 则模糊结论

$r_3 : \text{IF } x \text{ is } F \text{ THEN } z \text{ is } H$

的模糊关系 R_3 可由 R_1 与 R_2 的合成得到. 即

$$R_3 = R_1 \circ R_2,$$

这里的关系 R_1 、 R_2 和 R_3 都可以是前面所讨论过的 R_m 、 R_c 、 R_g 中的任何一种.

Example

设 $U = W = V = 1, 2, 3$, $E = 1/1 + 0.6/2 + 0.2/3$,
 $F = 0.8/1 + 0.5 + 0.1/3$, $G = 0.2/1 + 0.6 + 1/3$. 按 R_g 求 $E \times F \times G$ 上的关系 R .

先求 $E \times F$ 上的关系 R_1

$$R_1 = \begin{bmatrix} 0.8 & 0.5 & 0.1 \\ 1 & 0.5 & 0.1 \\ 1 & 1 & 0.1 \end{bmatrix}.$$

再求 $E \times G$ 上的关系 R_2 :

$$R_2 = \begin{bmatrix} 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

最后求 $E \times F \times G$ 上的关系 R ,

$$R = R_1 \circ R_2 = \begin{bmatrix} 0.2 & 0.6 & 0.8 \\ 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \end{bmatrix}.$$