人工智能

人工智能概述

主讲: 赵国亮

内蒙古大学电子信息工程学院

May 22, 2020

目录 I

不精确性推理方法

现实世界中的大多数问题是不精确、非完备的. 对于这些问题, 若采用前面所讨论的精确性推理方法显然是无法解决的. 为此, 人工智能需要研究不精确性的推理方法, 以满足客观问题的需求.


(一)
(二)
分数的意义
和性质
智慧广场
数与代数

不确定性推理的定义

什么是不确定性推理

- 不确定性推理泛指除精确推理以外的其它各种推理问题. 包括不完备、不精确知识的推理, 模糊知识的推理, 非单调性推理等.
- 不确定性推理过程实际上是一种从不确定的初始证据出发, 通过运用不确定性知识, 推出具有一定不确定性但却又是合理或基本合理的结论的思维过程.

为什么要采用不确定性推理

- 所需知识不完备. • 不精确所需知识描述模糊.
- 多种原因导致同一结论. • 问题的背景知识不足.
- 解题方案不唯一.

不确定性推理的基本问题

(1) 知识的不确定性的表示

- 考虑因素: 问题的描述能力, 推理中不确定性的计算.
- 含义: 知识的确定性程度, 或动态强度.
- 表示: 用概率 [0,1], 0 接近于假, 1 接近于真. 用可信度 [-1,1], 大于 0 接近于真, 小于 0 接近于假.

(2) 证据的非精确性表示

证据来源: 初始证据, 中间结论. 表示方式: 用概率或可信度.

含义

不确定的前提条件与不确定的事实匹配.

问题

前提是不确定的, 事实也是不确定的

方法

设计一个计算相似程度的算法, 给出相似的限度.

- 标志

相似度落在规定限度内为匹配, 否则为不匹配.

4. • 含义

知识的前提条件是多个证据的组合

4. ● 方法

最大最小方法, 如合取取最小、析取取最大.
概率方法, 按概率.

4. 非精确性的更新

主要问题
① 如何用证据的不确定性去更新结论的不确定性.
② 如何在推理中把初始证据的不确定性传递给最终结论.

解决方法

对① 不同推理方法的解决方法不同。

对② 不同推理方法的解决方法基本相同, 即把当前结论及其不确定性作为新的结论放入综合数据库, 依次传递, 直到得出最终结论。

非精确性结论的合成

含义: 多个不同知识推出同一结论, 且不确定性程度不同。

方法: 视不同推理方法而定。

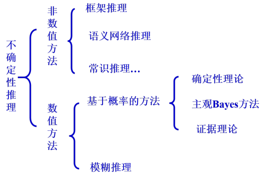

不确定性推理的概率论基础

在概率论中, 把试验中每一个可能出现的结果称为试验的一个样本点, 由全体样本点构成的集合称为样本空间.
表示: 通常用 D 表示样本空间, d 表示样本点.
概念: 由样本点构成的集合称为随机事件.

Example

1. 在掷币试验中, 若用 d_1 表示硬币的正面向上, 用 d_2 表示硬币的反面向上, 则该试验的样本空间为: $D = \{d_1, d_2\}$.
2. 在掷币试验中, 若用 A 表示硬币正面向上这一事件, 则有 $A = \{d_1\}$.

概率运算

常见运算

- 并事件：事件 A 与事件 B 至少有一个发生，记为 $A \cup B$.
- 交事件：事件 A 与事件 B 同时发生，记为 $A \cap B$.
- 互逆事件：事件 A 与 B 之间满足 “$A \cap B = \emptyset, A \cup B = D$”.

概率的统计定义

是通过某一事件出现的频率定义的. 频率:

$$f_n(A) = m/n, \tag{1}$$

式中, A 所讨论的事件, n 是试验的总次数, m 是实验中 A 发生的次数. 在同一组条件下所进行大量重复试验时, 如果事件 A 出现的频率总是在区间 $[0,1]$ 上的一个确定常数 p 附近摆动, 并且稳定于 p, 则称 p 为事件 A 的统计概率. 即

$$P(A) = p. \tag{2}$$

Example

在掷币试验中, 当掷币次数足够多时有

$$\mathsf{f}_{\mathsf{n}}(\text{正面向上}) = 0.5. \tag{3}$$

则称正面向上的概率为 0.5, 即

$$\mathsf{P}(\text{正面向上}) = 0.5. \tag{4}$$

统计概率的性质

性质

(1) 对任一事件 A, 有 $0 \le P(A) \le 1$.

(2) 必然事件 D 的概率 $P(D) = 1$, 不可能事件 Φ 的概率 $P(\emptyset) = 0$.

(3) 对任一事件 A, 有 $P(\neg A) = 1 - P(A)$.

(4) 设事件 $A_1, A_2, \cdots, A_k (k \le n)$ 是两两互不相容的事件, 即有 $A_i \cap A_j = \emptyset (i \ne j)$, 则 $P(\sum_{i=1}^{\infty} A_i) = \sum_{i=1}^{\infty} P(A_i)$.

(5) 设 A, B 是两个事件, 则 $P(A \cup B) = P(A) + P(B) - P(A \cap B)$.

条件概率

条件概率

设 A 与 B 是两个随机事件, $P(B) > 0$, 则称:

$$P(A|B) = P(A \cap B)/P(B). \quad (5)$$

为在事件 B 发生的条件下事件 A 的条件概率.

Example

设样本空间 D 是扑克牌中的 54 张牌, 即 D={红桃 A, 方块 A, 黑桃 A, 梅花 A, 红桃 2, 方块 2, $\cdots$, 小王, 大王}, 且有以下两个事件 $A = \{取花脸牌\}, B = \{取红桃牌\}$, 求在事件 B 发生的条件下事件 A 发生的概率 $P(A|B)$.

由于事件 B 已经发生, 因此以下事件 {取到红桃 A; 取到红桃 2; 取到红桃 3; $\cdots$; 取到红桃 K} 中必有一个出现.

而对事件 A, 在事件 B 发生的前提下, 只有以下事件 {取到红桃 J; 取到红桃 Q; 取到红桃 K 中的一个} 发生时事件 A 才能发生.

因此, 在事件 B 发生的条件下事件 A 发生的概率是 3/13.

全概率公式

设事件 $A_1, A_2, \cdots, A_n$ 满足:
(1) 任意两个事件都互不相容, 即当 $i \neq j$ 时, 有 $A_i \cap A_j = \emptyset, (i = 1, 2, \cdots, n_j = 1, 2, \cdots, n)$;
(2) $P(A_i) > 0 (i = 1, 2, \cdots, n)$;
(3) $D = \bigcup_{n=1}^{n} A_n$, 则对任何事件 B 由下式成立:

$$P(B) = \sum_{i=1}^{n} P(A_i) \times P(B|A_i). \tag{6}$$

该公式称为全概率公式, 它提供了一种计算 P(B) 的方法.

Bayes 定理

设事件 $A_1, A_2, \cdots, A_n$ 满足定理 6.1 规定的条件, 则对任何事件 B 有下式成立:

$$P(A_i|B) = \frac{P(A_i) \times P(B/A_i)}{\sum_{j=1}^{n} P\left(A_j\right) \times P\left(B/A_j\right)}, \ i = 1, 2, \cdots, n \tag{7}$$

该定理称为 Bayes 定理, 上式称为 Bayes 公式. 其中 $P(A_i)$ 是事件 A_i 的先验概率, $P(B|A_i)$ 是在事件 A_i 发生条件下事件 B 的条件概率; $P(A_i|B)$ 是在事件 B 发生条件下事件 A_i 的条件概率.

如果把全概率公式代入 Bayes 公式, 则有:

$$P(A_i|B) = \frac{P(A) \times P(B|A_i)}{P(B)}, i = 1, 2, \cdots, n. \tag{8}$$

即

$$P(A_i|B) \times P(B) = P(B_i|A) \times P(A_i) \quad i = 1, 2, \ldots, n. \tag{9}$$

这是 Bayes 公式的另一种形式. Bayes 定理给出了用逆概率 $P(B|A_i)$ 求原概率 $P(A_i|B)$ 的方法.

可信度的概念

可信度

是指人们根据以往经验对某个事物或现象为真的程度的一个判断，或者说是人们对某个事物或现象为真的相信程度.

例 2.1

沈强昨天没来上课，理由是头疼. 就此理由，只有以下两种可能：一是真的头疼了，理由为真；二是没有头疼，理由为假. 但就听话人而言，因不能确切知道，就只能某种程度上相信，即可信度.

CF 模型

可信度具有一定的主观性, 较难把握. 但对某一特定领域, 让该领域专家给出可信度还是可行的.

知识不确定性的表示形式

在 CF 模型中, 知识是用产生式规则表示的, 其一般形式为:

$$\text{IF} \quad E \quad \text{THEN} \quad H \quad (CF(H, E)),$$

其中, E 是知识的前提条件; H 是知识的结论; $CF(H, E)$ 是知识的可信度.

可信度的定义与性质

(1) E 可以是单一条件, 也可以是复合条件. 例如:

$$E=(E_1 \text{ OR } E_2) \text{ AND } E_3 \text{ AND } E_4$$

(2) H 可以是单一结论, 也可以是多个结论

(3) CF 是知识的静态强度, CF(H, E) 的取值为 $[-1, 1]$, 表示当 E 为真时, 证据对 H 的支持程度, 其值越大, 支持程度越大.

Example

IF 发烧 AND 流鼻涕 THEN 感冒 (0.8)

表示当某人确实有“发烧”及“流鼻涕”症状时, 则有 80% 的把握是患了感冒.

可信度的定义

在 CF 模型中, 把 CF(H, E) 定义为

$$\mathrm{CF}(\mathrm{H},\mathrm{E}) = \mathrm{MB}(\mathrm{H},\mathrm{E}) - \mathrm{MD}(\mathrm{H},\mathrm{E})$$

式中 MB 称为信任增长度, MB(H, E) 定义为

$$\mathrm{MB}(\mathrm{H},\mathrm{E}) = \begin{cases} 1, & \text{若}\mathrm{P}(\mathrm{H}) = 1 \\ \frac{\max\{\mathrm{P}(\mathrm{H}|\mathrm{E}),\mathrm{P}(\mathrm{H})\} - \mathrm{P}(\mathrm{H})}{1 - \mathrm{P}(\mathrm{H})}, & \text{否则} \end{cases} \tag{10}$$

MB 和 MD 的关系

MD 称为不信任增长度, MB(H, E) 定义为

$$\mathrm{MD}(H,E)=\begin{cases}1, & 若P(H)=0\\ \frac{\min\{P(H|E),P(E)\}-P(H)}{1-P(H)}, & 否则\end{cases} \quad (11)$$

① 当 $\mathrm{MB}(H,E)>0$ 时, 有 $P(H|E)>P(H)$, 即 E 的出现增加了 H 的概率;
② 当 $\mathrm{MD}(H,E)>0$ 时, 有 $P(H|E)<P(H)$, 即 E 的出现降低了 H 的概率.

根据前面对 CF(H, E) 可信度、MB(H, E) 信任增长度、MD(H, E) 不信增长度的定义, 可得到 CF(H, E) 的计算公式:

$$\mathrm{CF}(\mathrm{H},\mathrm{E})=\begin{cases}\mathrm{MB}(\mathrm{H},\mathrm{E})-0=\frac{\mathrm{P}(\mathrm{H}|\mathrm{E})-\mathrm{P}(\mathrm{H})}{1-\mathrm{P}(\mathrm{H})} & \text{若}\mathrm{P}(\mathrm{H}|\mathrm{E})>\mathrm{P}(\mathrm{H})\\ 0 & \text{若}\mathrm{P}(\mathrm{H}|\mathrm{E})=\mathrm{P}(\mathrm{H})\\ 0-\mathrm{MD}(\mathrm{H},\mathrm{E})=-\frac{\mathrm{P}(\mathrm{H})-\mathrm{P}(\mathrm{H}|\mathrm{E})}{\mathrm{P}(\mathrm{H})} & \text{若}\mathrm{P}(\mathrm{H}|\mathrm{E})<\mathrm{P}(\mathrm{H})\end{cases} \tag{12}$$

分别解释 $\mathrm{CF}(\mathrm{H},\mathrm{E})>0, \mathrm{CF}(\mathrm{H},\mathrm{E})=0, \mathrm{CF}(\mathrm{H},\mathrm{E})<0$.

可信度的性质

- 互斥性

对同一证据，它不可能既增加对 H 的信任程度，又同时增加对 H 的不信任程度，这说明 MB 与 MD 是互斥的. 即有如下互斥性：• 当 $\mathrm{MB}(\mathrm{H},\mathrm{E}) > 0$时, $\mathrm{MD}(\mathrm{H},\mathrm{E}) = 0$.
• 当 $\mathrm{MD}(\mathrm{H},\mathrm{E}) > 0$时, $\mathrm{MB}(\mathrm{H},\mathrm{E}) = 0$.

当 $\mathsf{CF}(\mathsf{H},\mathsf{E})=1$ 时, 有 $\mathsf{P}(\mathsf{H}/\mathsf{E})=1$, 它说明由于 E 所对应证据的出现使 H 为真. 此时, $\mathsf{MB}(\mathsf{H},\mathsf{E})=1, \mathsf{MD}(\mathsf{H},\mathsf{E})=0$.

当 $\mathsf{CF}(\mathsf{H},\mathsf{E})=-1$ 时, 有 $\mathsf{P}(\mathsf{H}/\mathsf{E})=0$, 说明由于 E 所对应证据的出现使 H 为假. 此时, $\mathsf{MB}(\mathsf{H},\mathsf{E})=0, \mathsf{MD}(\mathsf{H},\mathsf{E})=1$.

当 $\mathsf{CF}(\mathsf{H},\mathsf{E})=0$ 时, 有 $\mathsf{MB}(\mathsf{H},\mathsf{E})=0$、$\mathsf{MD}(\mathsf{H},\mathsf{E})=0$. 前者说明 E 所对应证据的出现不证实 H; 后者说明 E 所对应证据的出现不否认 H.

- 典型值对 H 的信任增长度等于对非 H 的不信任增长度.

$$
\begin{aligned}
MD(\neg H, E) &= \frac{P(\neg H|E) - P(\neg H)}{-P(\neg H)} = \frac{(1 - P(H|E)) - (1 - P(H))}{-(1 - P(H))} \\
&= \frac{-P(H|E) + P(H)}{-(1 - P(H))} = \frac{-(P(H|E) - P(H))}{-(1 - P(H))} \\
&= \frac{P(H|E) - P(H)}{1 - P(H)} = MB(H, E), \qquad \text{信任增长度}
\end{aligned} \tag{13}
$$

再根据 CF 的定义和 MB、MD 的互斥性有

$$\begin{aligned}
\mathsf{CF}(\mathsf{H},\mathsf{E})+\mathsf{CF}(\neg\mathsf{H},\mathsf{E}) &= (\mathsf{MB}(\mathsf{H},\mathsf{E})-\mathsf{MD}(\mathsf{H},\mathsf{E}))+(\mathsf{MB}(\neg\mathsf{H},\mathsf{E})-\mathsf{MD}(\neg\mathsf{H},\mathsf{E})) \\
&= (\mathsf{MB}(\mathsf{H},\mathsf{E})-0)+(0-\mathsf{MD}(\neg\mathsf{H},\mathsf{E})), \qquad \text{(由互斥性)} \\
&= \mathsf{MB}(\mathsf{H},\mathsf{E})-\mathsf{MD}(\neg\mathsf{H},\mathsf{E})=0
\end{aligned}$$

它说明

(1) 对 H 的信任增长度等于对非 H 的不信任增长度
(2) 对 H 的可信度与非 H 的可信度之和等于 0
(3) 可信度不是概率, 不满足

$$\mathsf{P}(\mathsf{H})+\mathsf{P}(\neg\mathsf{H})=1, 0\le \mathsf{P}(\mathsf{H}),\mathsf{P}(\neg\mathsf{H})\le 1.$$

(5) 对同一前提 E, 若支持若干个不同的结论 H_i $(i = 1, 2, \cdots, n)$, 则如果发现专家给出的知识有如下情况

$$CF(H_1, E) = 0.7, CF(H_2, E) = 0.4.$$

则因 $0.7 + 0.4 = 1.1 > 1$ 为非法, 应进行调整或规范化.

证据不确定性的表示

不确定性的表示

证据的不确定性也是用可信度来表示的, 其取值范围也为 $[-1, 1]$.

- 若 E 为初始证据, 其值由用户给出.
- 若 E 为中间结论, 其值可通过计算得到.

可信度的含义

- CF$(E) = 1$, 证据 E 肯定它为真.
- CF$(E) = -1$, 证据 E 肯定它为假.
- CF$(E) = 0$, 对证据 E 一无所知.
- $0 <$ CF$(E) < 1$, 证据 E 以 CF(E) 程度为真.
- $-1 <$ CF$(E) < 0$, 证据 E 以 CF(E) 程度为假.

否定证据不确定性的计算

$$\mathrm{CF}(\neg E) = -\mathrm{CF}(E). \tag{14}$$

组合证据不确定性的计算

对证据的组合形式可分为“合取”与“析取”两种基本情况.

- 合取: 当组合证据是多个单一证据的组合时, 即 $E = E_1$ AND E_2 AND $\cdots$ AND E_n 时, 若已知 $\mathrm{CF}(E_1), \mathrm{CF}(E_2), \cdots, \mathrm{CF}(E_n)$, 则

$$\mathrm{CF}(E) = \min\{\mathrm{CF}(E_1), \mathrm{CF}(E_2), \cdots, \mathrm{CF}(E_n)\}. \tag{15}$$

- 析取

当组合证据是多个单一证据的析取时, 即 $E = E_1$ OR E_2 OR $\cdots$ OR E_n 时, 若已知 $CF(E_1), CF(E_2), \cdots, CF(E_n)$, 则

$$CF(E) = \max\{CF(E_1), CF(E_2), \cdots, CF(E_n)\}. \tag{16}$$

CF 模型中的不确定性推理实际上是从不确定的初始证据出发, 不断运用相关的不确性知识, 逐步推出最终结论和该结论可信度的过程.

不确定性的更新

每一次运用不确定性知识，都需要由证据的不确定性和知识的不确定性去计算结论的不确定性.

不确定性的更新公式

$$\mathrm{CF}(\mathrm{H}) = \mathrm{CF}(\mathrm{H}, \mathrm{E}) \times \max\{0, \mathrm{CF}(\mathrm{E})\}. \tag{17}$$

若 $\mathsf{CF}(\mathsf{E}) < 0$, 则

$$\mathsf{CF}(\mathsf{H}) = 0, \tag{18}$$

即该模型没考虑 E 为假对 H 的影响. 若 $\mathsf{CF}(\mathsf{E}) = 1$, 则

$$\mathsf{CF}(\mathsf{H}) = \mathsf{CF}(\mathsf{H}, \mathsf{E}), \tag{19}$$

即规则强度 $\mathsf{CF}(\mathsf{H}, \mathsf{E})$ 实际上是在 E 为真时, H 的可信度.

结论不确定性的合成

当有多条知识支持同一个结论, 且这些知识的前提相互独立, 结论的可信度又不相同时, 可利用不确定性的合成算法求出结论的综合可信度. 设有知识:

$$\text{IF } E_1 \text{ THEN } H(CF(H, E_1)), \tag{20}$$

$$\text{IF } E_2 \text{ THEN } H(CF(H, E_2)). \tag{21}$$

则结论 H 的综合可信度可分以下两步计算:

(1) 分别对每条知识求出其 $CF(H)$. 即

$$CF_1(H) = CF(H, E_1) \times \max\{0, CF(E_1)\}, \tag{22}$$

$$CF_2(H) = CF(H, E_2) \times \max\{0, CF(E_2)\}. \tag{23}$$

(2) 用如下公式求 E_1 与 E_2 对 H 的综合可信度

$$CF(H)=\begin{cases} CF_1(H)+CF_2(H)-CF_1(H)\times CF_2(H), & 若CF_1(H)\geq 0, 且CF_2(H)\geq 0 \\ CF_1(H)+CF_2(H)+CH_1(H)\times CF_2(H), & 若CF_1(H)<0 且CF(H)<0 \\ \frac{CF_1(H)+CF_2(H)}{1-\min\{CF_1(H),|CF_2(H)|\}}, & CF_1(H)<0 且CF_2(H)异号 \end{cases} \tag{24}$$

Example

设有如下一组知识:

r_1: IF E1 THEN H(0.9) r_2: IF E2 THEN H(0.6) r_3: IF E3 THEN H(-0.5) r_4: IF E4 AND (E5 OR E6) THEN E1(0.8)

已知: $CF(E_2) = 0.8, CF(E_3) = 0.6, CF(E_4) = 0.5, CF(E_5) = 0.6, CF(E_6) = 0.8$, 求 $CF(H)$.

由 r_4 得到:

$$
\begin{aligned}
CF(E_1) &= 0.8 \times \max\{0, CF(E_4 \text{ AND } (E_5 \text{ OR } E_6))\} \\
&= 0.8 \times \max\{0, \min\{CF(E_4), CF(E_5 \text{ OR } E_6)\}\} \\
&= 0.8 \times \max\{0, \min\{CF(E_4), \max\{CF(E_5), CF(E_6)\}\}\} \\
&= 0.8 \times \max\{0, \min\{CF(E_4), \max\{0.6, 0.8\}\}\} \\
&= 0.8 \times \max\{0, \min\{0.5, 0.8\}\} \\
&= 0.8 \times \max\{0, 0.5\} = 0.4.
\end{aligned}
$$

由 r_1

$$
\begin{aligned}
CF_1(H) &= CF(H, E_1) \times \max\{0, CF(E_1)\} \\
&= 0.9 \times \max\{0, 0.4\} = 0.36.
\end{aligned} \tag{25}
$$

由 r_2 得到:

$$\begin{aligned}\mathsf{CF}_2(\mathsf{H}) &= \mathsf{CF}(\mathsf{H},\mathsf{E}_2)\times\max\{0,\mathsf{CF}(\mathsf{E}_2)\}\\ &= 0.6\times\max\{0,0.8\} = 0.48.\end{aligned}\tag{26}$$

由 r_3 得到:

$$\begin{aligned}\mathsf{CF}_3(\mathsf{H}) &= \mathsf{CF}(\mathsf{H},\mathsf{E}_3)\times\max\{0,\mathsf{CF}(\mathsf{E}_3)\}\\ &= -0.5\times\max\{0,0.6\} = -0.3.\end{aligned}\tag{27}$$

根据结论不精确性的合成算法, $\mathsf{CF}_1(\mathsf{H})$ 和 $\mathsf{CF}_2(\mathsf{H})$ 同号, 有:

$$\begin{aligned}\mathsf{CF}_{1,2}(\mathsf{H}) &= \mathsf{CF}_1(\mathsf{H})+\mathsf{CF}_2(\mathsf{H})-\mathsf{CF}_1(\mathsf{H})\times\mathsf{CF}_2(\mathsf{H})\\ &= 0.36+0.48-0.36\times0.48\\ &= 0.84-0.17 = 0.67.\end{aligned}\tag{28}$$

$CF_{12}(H)$ 和 $CF_3(H)$ 异号, 有:

$$
\begin{aligned}
CF_{1,2,3}(H) &= \frac{CF_{1,2}(H) + CF_3(H)}{1 - \min\{|CF_{1,2}(H)|, |CF_3(H)|\}} \\
&= \frac{0.67 - 0.3}{1 - \min\{0.67, 0.3\}} = \frac{0.37}{0.7} \\
&= 0.53.
\end{aligned} \tag{29}
$$

主观 Bayes 方法

在主观 Bayes 方法中, 知识是用产生式表示的, 其形式为:

$$\text{IF E THEN (LS, LN) H,} \tag{30}$$

其中, (LS, LN) 用来表示该知识的知识强度, LS(充分性度量) 和 LN(必要性度量) 的表示形式分别为:

$$\mathrm{LS} = \frac{\mathrm{P}(\mathrm{E}|\mathrm{H})}{\mathrm{P}(\mathrm{E}|\neg\mathrm{H})}. \tag{31}$$

$$\mathrm{LN} = \frac{\mathrm{P}(\neg\mathrm{E}|\mathrm{H})}{\mathrm{P}(\neg\mathrm{E}|\neg\mathrm{H})} = \frac{1-\mathrm{P}(\mathrm{E}|\mathrm{H})}{1-\mathrm{P}(\mathrm{E}|\neg\mathrm{H})}. \tag{32}$$

LS 和 LN 含义的讨论

由本章第 7 节的 Bayes 公式可知:

$$P(H|E) = \frac{P(E|H) \times P(H)}{P(E)}, \tag{33}$$

$$P(\neg H|E) = \frac{P(E|\neg H) \times P(\neg H)}{P(E)}. \tag{34}$$

两式相除得:

$$\frac{P(H|E)}{P(\neg H|E)} = \frac{P(E|H)}{P(E|\neg H)} \times \frac{P(H)}{P(\neg H)}. \tag{35}$$

为讨论方便, 下面引入概念 几率函数 1

$$O(X) = \frac{P(X)}{1 - P(X)}, P(X) = \frac{O(X)}{1 + O(X)}. \tag{36}$$

可见, X 的几率等于 X 出现的概率与 X 不出现的概率之比, P(X) 与 O(X) 的变化一致, 且有:

$$P(X) = 0, O(X) = 0; \tag{37}$$

$$P(X) = 1, O(X) = +\infty. \tag{38}$$

即把取值为 $[0, 1]$ 的 P(X) 放大为取值为 $[0, +\infty]$ 的 O(X)。

把 (33) 式代入 (37) 式有:

$$O(H|E) = \frac{P(E|H)}{P(E|\neg H)} \times O(H). \tag{39}$$

再把 LS 代入此式, 可得:

$$O(H|E) = LS \times O(H). \tag{40}$$

同理可得到关于 LN 的公式:

$$\frac{P(H|\neg E)}{P(\neg H|\neg E)} = \frac{P(E|H)}{P(\neg E|\neg H)} \times \frac{P(H)}{P(-H)}, \tag{41}$$

$$O(H|\neg E) = LN \times O(H). \tag{42}$$

式 (41) 和 (42) 就是修改的 Bayes 公式.

证据理论

证据理论是由德普斯特 (A. P. Dempster) 首先提出, 并有沙佛 (G. Shafer) 进一步发展起来的用于处理不确定性的一种理论.

也称 DS (Dempster-Shafer) 理论

它将概率论中的单点赋值扩展为集合赋值, 可以处理由“不知道”所引起的不确定性, 比主观 Bayes 方法有着更大的灵活性.

在 DS 理论中, 可以分别用信任函数、似然函数及类概率函数来描述知识的精确信任度、不可驳斥信任度及估计信任度.

引言

DS 理论处

DS 理论处理的是集合上的不确定性问题, 为此需要先建立命题与集合之间的一一对应关系, 以把命题的不确定性问题转化为集合的不确定性问题.

设 Ω 为样本空间, 且 Ω 中的每个元素都相互独立, 则由 Ω 的所有子集构成的幂集记为 2^Ω.
当 Ω 中的元素个数为 N 时, 则其幂集 2^Ω 的元素个数为 2^N, 且其中的每一个元素都对应于一个关于 x 取值情况的命题.

Example

设 $\Omega = \{$红, 黄, 白$\}$, 求 Ω 的幂集 2^{Ω}.

Ω 的幂集可包括如下子集:

$$\mathrm{A}_0 = \emptyset, \mathrm{A}_1 = \{\text{红}\}, \mathrm{A}_2 = \{\text{黄}\}, \mathrm{A}_3 = \{\text{白}\},$$
$$\mathrm{A}_4 = \{\text{红, 黄}\}, \mathrm{A}_5 = \{\text{红, 白}\}, \mathrm{A}_6 = \{\text{黄, 白}\}, \mathrm{A}_7 = \{\text{红, 黄, 白}\}$$

其中, $\emptyset$ 表示空集, 空集也可表示为 $\{\}$. 上述子集的个数正好是 $2^3 = 8$.

Example

设函数 m : $2^{\Omega} \to [0,1]$, 且满足

$$\mathsf{m}(\Phi) = 0, \sum_{A \subseteq \Omega} \mathsf{m}(A) = 1 \tag{43}$$

则称 m 是 2^{Ω} 上的概率分配函数, m(A) 称为 A 的基本概率数.

对例 6 若定义 2^{Ω} 上的一个基本函数 m:

$$\begin{aligned}&\mathsf{m}(\{红\},\{黄\},\{白\},\{红,黄\},\{红,白\},\{黄,白\},\{红,黄,白\})\\&=(0,0.3,0,0.1,0.2,0.2,0,0.2).\end{aligned} \tag{44}$$

其中, $(0, 0.3, 0, 0.1, 0.2, 0.2, 0, 0.2)$ 分别是幂集 2^{Ω} 中各个子集的基本概率数. 显然 m 满足概率分配函数的定义.

对概率分配函数的说明

(1) 概率分配函数的作用是把 Ω 的任一子集映射为 $[0, 1]$ 上的一个数 m(A)

- 当 $A \subset \Omega$, 且 A 由单个元素组成时, 则 m(A) 表示对 A 的精确信任度;
- 当 $A \subset \Omega$、$A \neq \Omega$, 且 A 由多个元素组成时, m(A) 也表示对 A 的精确信任度, 但却不知道这部分信任度该分给 A 中哪些元素;
- 当 $A \subseteq \Omega$ 时, 则 m(A) 也表示不知道该如何分配的子集部分.

Example

对上例所给出的有限集 Ω 及基本函数 m, 当

- A $=$\{红\} 时, 有 m$(\text{A}) = 0.3$, 它表示对命题 "x 是红色" 的精确信任度为 0.3.

- B $=$\{红, 黄\} 时, 有 m$(\text{B}) = 0.2$, 它表示对命题 "x 或者是红色, 或者是黄色" 的精确信任度为 0.2, 却不知道该把这 0.2 分给 \{红\} 还是分给 \{黄\}.

- C $= \Omega =$\{红, 黄, 白\} 时, 有 m$(\Omega) = 0.2$, 表示不知道该对这 0.2 如何分配, 但知道它不属于红, 就一定属于 \{黄\} 或 \{白\} .

(2) 概率分配函数不是概率

Example

在例 6.5 中, m 符合概率分配函数的定义, 但

$$\mathrm{m}(\{红\}) + \mathrm{m}(\{黄\}) + \mathrm{m}(\{白\}) = 0.3 + 0 + 0.1 = 0.4 < 1. \tag{45}$$

因此 m 不是概率, 因为概率 P 要求: $\mathrm{P}(\{红\}) + \mathrm{P}(黄) + \mathrm{P}(白) = 1.$

信任函数

信任函数 Bel: $2^{\Omega} \to [0,1]$ 为

$$\mathrm{Bel}(A) = \sum_{B \subseteq A} m(B), \tag{46}$$

其中, 2^{Ω} 是 Ω 的幂集. Bel又称为下限函数, Bel(A) 表示对 A 的总的信任度.

Example

对例 6.5 有

$$\mathrm{Bel}(\{红\}) = 0.3 \tag{47}$$

$$\begin{aligned}\mathrm{Bel}(\{红, 白\}) &= \mathrm{m}(\{红\}) + \mathrm{m}(\{白\}) + \mathrm{m}(\{红, 白\}) \\ &= 0.3 + 0.1 + 0.2 = 0.6.\end{aligned} \tag{48}$$

根据定义还可以得到:

$$\begin{aligned}&\mathrm{Bel}\ (\Phi) = \mathrm{m}(\Phi) = 0, \\ &\mathrm{Bel}\ (\Omega) = \textstyle\sum_{B\subseteq\Omega} \mathrm{m}(B) = 1.\end{aligned} \tag{49}$$

Example

对例 7 有

$$\mathsf{Bel}(\emptyset) = \mathsf{m}(\emptyset) = 0 \tag{50}$$

$$\begin{aligned}\mathsf{Bel}(\{红, 黄, 白\}) &= \mathsf{m}(\emptyset) + \mathsf{m}(\{红\}) + \mathsf{m}(\{黄\}) + \mathsf{m}(\{白\}) + \mathsf{m}(\{红, 黄\}) \\ &+ (\{红, 白\}) + (\{黄, 白\}) + (\{红, 黄, 白\}) \\ &= 0 + 0.3 + 0 + 0.1 + 0.2 + 0.2 + 0 + 0.2 = 1.\end{aligned} \tag{51}$$

似然函数 1 似然函数 $\mathsf{P_l} : 2^{\Omega} \to [0, 1]$ 为

$$\mathsf{P_l}(\mathsf{A}) = 1 - \mathsf{Bel}(\neg \mathsf{A}), \mathsf{A} \subseteq \Omega, \tag{52}$$

其中, $\neg \mathsf{A} = \Omega - \mathsf{A}.$

似然函数又称为不可驳斥函数或上限函数. 由于 $\mathrm{Bel}(\neg A)$ 表示对 $\neg A$ 的信任度, 即 A 为假的信任度, 因此, $P_l(A)$ 表示对 A 为非假的信任度.

Example

以例 7 为例:

$$\begin{aligned}
P_l(\{红\}) &= 1 - \mathrm{Bel}(\neg\{红\}) \\
&= 1 - \mathrm{Bel}(\{黄, 白\}) \\
&= 1 - (m(\{黄\}) + m(\{白\}) + m(\{黄, 白\})) \\
&= 1 - (0 + 0.1 + 0) = 0.9.
\end{aligned} \tag{53}$$

这里的 0.9 是“红”为非假的信任度. 由于“红”为真的精确信任度为 0.3, 而剩下的 0.9-0.3=0.6, 则是知道非假, 但却不能肯定为真的那部分.

Example

再如:

$$\mathsf{P_l}(\{黄, 白\}) = 1 - \mathsf{Bel}(\neg\{黄, 白\}) = 1 - \mathsf{Bel}(\{红\}) = 1 - 0.3 = 0.7. \tag{54}$$

这里的 0.7 的含义与上面分析类似.

似然函数的另外一种计算办法:

$$\sum_{\{红\}\cap B=\emptyset} m(B) = 0.3 + 0.2 + 0.2 + 0.2 = 0.9. \tag{55}$$

由于

$$\sum_{\{黄, 白\}\cap B=\emptyset} m(B) = 0 + 0.1 + 0 + 0.2 + 0.2 + 0.2 = 0.7. \tag{56}$$

可见, $P_l(\{红\}), P_l(\{黄, 白\})$ 亦可分别用下式计算:

$$P_l(\{红\}) = \sum_{\{红\}\cap B=\emptyset} m(B), \qquad P_l(\{黄, 白\}) = \sum_{\{黄, 白\}\cap B=\emptyset} m(B). \tag{57}$$

一般可得公式

$$P_l(A) = \sum_{A\cap B\neq\Phi} m(B). \tag{58}$$

其证明见教材.

信任函数和似然函数之间存在关系:

$$P_l(A) \geq Bel(A). \tag{59}$$

Proof.

$$
\begin{aligned}
\mathrm{Bel}(A) + \mathrm{Be}(\mathcal{T}A) &= \sum_{B \in A} m(B) + \sum_{C_{E-A}} m(C) \leq \sum_{E \subseteq \Omega} m(E) = 1. \\
P_l(A) - \mathrm{Bel}(A) &= 1 - \mathrm{Bel}(\neg A) - \mathrm{Bel}(A) \\
&= 1 - (\mathrm{Bel}(\neg A) + \mathrm{Bel}(A)) \geq 0. \\
P_l(A) &\geq \mathrm{Bel}(A),
\end{aligned}
\tag{60}
$$

由于 Bel(A)和$P_l(A)$ 分别表示 A 为真的信任度和 A 为非假的信任度, 因此, 可分别称 Bel(A)和$P_l(A)$ 为对 A 信任程度的下限和上限, 记为: $A[\mathrm{Bel}(A), P_l(A)]$. □

Example

在前面的例子中

$$\text{Bel}(\{红\}) = 0.3, \text{P}_\text{l}(\{红\}) = 0.9. \qquad (61)$$

即: $\{红\} = [0.3, 0.9]$. 它表示对 {红} 的精确信任度为 0.3, 不可驳斥部分为 0.9, 肯定不是 {红} 的为 0.1.

同理可以求得

- {黄}[0, 0.4] {白}[0.1, 0.5];
- {红, 黄}[0.5, 0.9] {红, 白}[0.6, 1];
- {黄, 白}[0.1, 0.7] {红, 黄, 白}[1, 1];
- { }[0, 0].

一些典型值的含义

$A[0,1]$: 说明对 A 一无所知. 其中, $\mathrm{Bel}(A) = 0$, 说明对 A 无信任; 再由 $P_l(A) = 1 - \mathrm{Bel}(\neg A) = 1$, 可知 $\mathrm{Bel}(\neg A) = 0$, 说明对 $\neg A$ 也没有信任.

- $A[0,0]$: 说明 A 为假. 即 $\mathrm{Bel}(A) = 0, \mathrm{Bel}(\neg A) = 1$.

- $A[1,1]$: 说明 A 为真. 即 $\mathrm{Bel}(A) = 1, \mathrm{Bel}(\neg A) = 0$.

- A$[0.6, 1]$: 说明对 A 部分信任. 即 Bel$(A) = 0.6$, Bel$(\neg A) = 0$.

- A$[0, 0.4]$: 说明对 $\neg$A 部分信任. 即 Bel$(A) = 0$, Bel$(\neg A) = 0.6$.

- A$[0.3, 0.9]$: 说明对 A 和 $\neg$A 都有部分信任. 其中, Bel$(A) = 0.3$, 说明对 A 为真有 0.3 的信任度;

Bel$(\neg A) = 1 - 0.9 = 0.1$, 说明对 A 为假有 0.1 的信任度. 因此, A$[0.3, 0.9]$ 表示对 A 为真的信任度比 A 为假的信任度稍高一些.

当证据来源不同时, 可能会得到不同的概率分配函数. 例如, 对

$$\Omega = \{红, 黄\}. \tag{62}$$

从不同知识源得到的两个概率分配函数

$$m_1(\{\}, \{红\}, \{黄\}, \{红, 黄\}) = (0, 0.4, 0.5, 0.1). \tag{63}$$

$$m_2(\{\}, \{红\}, \{黄\}, \{红, 黄\}) = (0, 0.6, 0.2, 0.2). \tag{64}$$

采用德普斯特提出的求正交和的方法来组合这些函数 概率分配函数的正交和 1 设 m_1 和 m_2 是两个不同的概率分配函数, 则其正交和 $m = m_1 \oplus m_2$ 满足

$$m(\Phi) = 0, m(A) = K^{-1} \times \sum_{x \cap y = A} m_1(x) \times m_2(y). \tag{65}$$

其中:

$$K = 1 - \sum_{x \cap y = \Phi} m_1(x) \times m_2(y) = \sum_{x \cap y \neq \Phi} m_1(x) \times m_2(y). \tag{66}$$

如果 $K \neq 0$, 则正交和也是一个概率分配函数; 如果 $K = 0$, 则不存在正交和 m, 称 m_1 与 m_2 矛盾.

Example

设 $\Omega = \{a, b\}$, 且从不同知识源得到的概率分配函数分别为

$$m_1(\{\}, \{a\}, \{b\}, \{a, b\}) = (0, 0.3, 0.5, 0.2), \tag{67}$$

$$m_2(\{\}, \{a\}, \{b\}, \{a, b\}) = (0, 0.6, 0.3, 0.1). \tag{68}$$

求正交和 $m = m_1 \oplus m_2$.

先求 K

$$K = 1 - \sum_{x \cap y = \Phi} m_1(x) \times m_2(y) \tag{69}$$

$$= 1 - (m_1(\{a\}) \times m_2(\{b\}) + m_1(\{b\}) \times m_2(\{a\})) \tag{70}$$

$$= 1 - (0.3 \times 0.3 + 0.5 \times 0.6) = 0.61. \tag{71}$$

再求 $m(\{a\}, \{b\}, \{a, b\})$, 由于

$$\begin{aligned} m(\{a\}) &= \frac{1}{0.61} \times \sum_{x \cap y = \{a\}} m_1(x) \times m_2(y) \\ &= \frac{1}{0.61} \times (m_1(\{a\}) \times m_2(\{a\}) + m_1(\{a\}) \times m_2(\{a, b\}) + m_1(\{a, b\}) \times m_2(\{a\})) \\ &= \frac{1}{0.61} \times (0.3 \times 0.6 + 0.3 \times 0.1 + 0.2 \times 0.6) = 0.54. \end{aligned} \tag{72}$$

同理可求得

$$m(\{b\}) = 0.43, \tag{73}$$

$$m(\{a,b\}) = 0.03. \tag{74}$$

故有

$$m(\{\},\{a\},\{b\},\{a,b\}) = \{0, 0.54, 0.43, 0.03\}. \tag{75}$$

对于多个概率分配函数的组合, 方法类似.

Bel(A) 和 $P_l(A)$ 分别表示命题 A 的信任度的下限和上限, 同时也可用来表示知识强度的下限和上限.

从信任函数和似然函数的定义看, 它们都是建立在概率分配函数之上的, 可见不同的概率分配函数将得到不同的推理模型.

一个特殊的概率分配函数建立的推理模型

设 $\Omega = s_1, s_2, \cdots, s_n$, m 为定义在 2^Ω 上的概率分配函数, 且 m 满足

$$\begin{aligned}
&(1)\ m(\{s_i\}) \geq 0 \\
&(2)\ \sum_{i=1}^{n} m(\{s_i\}) \leq 1 \qquad\qquad A \subset \Omega, |A| >> 1 \text{或者} |A| = 0 \Rightarrow m(A) = 0. \\
&(3)\ m(\Omega) = 1 - \sum_{i=1}^{n} m(\{s_i\}).
\end{aligned} \tag{76}$$

其中, |A| 表示命题 A 所对应的集合中的元素个数. 该概率分配函数的特殊性:

① 只有当子集中的元素个数为 1 时, 其概率分配数才有可能大于 0;

② 当子集中有多个或 0 个元素, 且不等于全集时, 其概率分配数均为 0;

③ 全集 Ω 的概率分配数按 (3) 计算.

Example

1. 设 $\Omega=\{红, 黄, 白\}$, 有如下概率分配函数

$$m(\{\},\{红\},\{黄\},\{白\},\{红, 黄, 白\})=(0,0.6,0.2,0.1,0.1). \tag{77}$$

其中: $m(\{\},\{红\},\{黄\},\{白\},\{红, 黄, 白\})=0$, 可见, m 符合上述概率分配函数的定义.

2. 对任何命题 $A\subset\Omega$, 其信任函数为

$$\begin{aligned}
Bel(A) &= \sum_{s_i\in A} m(\{s_i\}) \\
Bel(\Omega) &= \sum_{B\subseteq\Omega} m(B)=\sum_{i=1}^{n} m(\{s_i\})+m(\Omega)=1.
\end{aligned} \tag{78}$$

其似然函数

对任何命题 $A \subset \Omega$, 其似然函数为

$$P_l(A) = 1 - Bel(\neg A) = 1 - \sum_{s_i \in \neg A} m(\{s_i\}) = 1 - \left[\sum_{i=1}^{n} m(\{s_i\}) - \sum_{s_i \in A} m(\{s_i\})\right]$$

$$= 1 - [1 - m(\Omega) - Bel(A)]$$

$$= m(\Omega) + Bel(A). \tag{79}$$

$$P_l(\Omega) = 1 - Bel(\neg\Omega) = 1 - Bel(\Phi) = 1. \tag{80}$$

可以看出, 对任意命题 $A \subset \Omega$ 和 $B \subset \Omega$ 均有:

$$P_l(A) - Bel(A) = P_l(B) - Bel(B) = m(\Omega). \tag{81}$$

它表示对 A(或 B) 不知道的程度.

Example

设 $\Omega=\{$红, 黄, 白$\}$, 概率分配函数

$$\mathrm{m}(\{\},\{红\},\{黄\},\{红, 黄\},\{红, 黄, 白\})=(0,0.6,0.2,0.1,0.1). \tag{82}$$

$A=\{$红, 黄$\}$, 求 $\mathrm{m}(\Omega)$、$\mathrm{Bel}(A)$和$\mathrm{P_l}(A)$ 的值.

$$\mathrm{m}(\Omega)=1-[\mathrm{m}(\{红\})+\mathrm{m}(\{黄\})+\mathrm{m}(\{白\})]=1-(0.6+0.2+0.1)=0.1. \tag{83}$$

$$\mathrm{Bel}(\{红, 黄\})=\mathrm{m}(\{红\})+\mathrm{m}(\{黄\})=0.6+0.2=0.8. \tag{84}$$

$$\mathrm{P_l}(\{红, 黄\})=\mathrm{m}(\Omega)+\mathrm{Bel}(\{红, 黄\})=0.1+0.8=0.9. \tag{85}$$

或 $\mathrm{P_l}(\{红, 黄\})=1-\mathrm{Bel}(\neg\{红, 黄\})=1-\mathrm{Bel}(\{白\})=1-0.1=0.9.$

基本概率分配函数的正交和

设 m_1 和 m_2 是 2^Ω 上的基本概率分配函数，它们的正交和定义为

$$m(\{s_i\}) = K^{-1} \times [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \quad (86)$$

Example

设 $\Omega = \{红, 黄, 白\}$，概率分配函数

$$m(\{\}, \{红\}, \{黄\}, \{白\}, \{红, 黄, 白\}) = (0, 0.6, 0.2, 0.1, 0.1). \quad (87)$$

$A = \{红, 黄\}$，求 $m(\Omega), Bel(A)$ 和 $P_l(A)$ 的值.

$$\begin{aligned} \mathsf{m}(\Omega) &= 1 - [\mathsf{m}(\{红\}) + \mathsf{m}(\{黄\}) + \mathsf{m}(\{白\})] \\ &= 1 - (0.6 + 0.2 + 0.1) = 0.1. \end{aligned} \tag{88}$$

$$\mathsf{Bel}(\{红, 黄\}) = \mathsf{m}(\{红\}) + \mathsf{m}(\{黄\}) = 0.6 + 0.2 = 0.8. \tag{89}$$

$$\mathsf{P_l}(\{红, 黄\}) = \mathsf{m}(\Omega) + \mathsf{Bel}(\{红, 黄\}) = 0.1 + 0.8 = 0.9. \tag{90}$$

另一形式

$$\mathsf{P_l}(\{红, 黄\}) = 1 - \mathsf{Bel}(\neg\{红, 黄\}) = 1 - \mathsf{Bel}(白) = 1 - 0.1 = 0.9. \tag{91}$$

概率分配函数的正交和

设 m_1 和 m_2 是 2^{Ω} 上的基本概率分配函数, 分配函数的正交和定义为

$$m(\{s_i\}) = K^{-1} \times [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \tag{92}$$

其中,

$$K = m_1(\Omega) \times m_2(\Omega) + \sum_{i=1}^{n} [m_1(s_i) \times m_2(s_i) + m_1(s_i) \times m_2(\Omega) + m_1(\Omega) \times m_2(s_i)]. \tag{93}$$

类概率函数

设 Ω 为有限域, 对任何命题 $A \subset \Omega$, 命题 A 的类概率函数为

$$f(A) = Bel(A) + \frac{|A|}{|\Omega|} \times [P_l(A) - Bel(A)], \tag{94}$$

其中, $|A|$ 和 $|\Omega|$ 分别是 A 及 Ω 中元素的个数.

类概率函数 f(A) 的性质

(1) $\sum_{i=1}^{n} f(\{S_i\}) = 1.$

$$
\begin{aligned}
\because f(\{s_i\}) &= \mathrm{Bel}(\{s_i\}) + \frac{|\{s_i\}|}{|\Omega|} \times [P_l(\{s_i\}) - \mathrm{Bel}(\{S_i\})] \\
&= m(\{s_i\}) + \frac{1}{n} \times m(\Omega),\ i = 1, 2, \ldots, n. \\
\therefore \sum_{i=1}^{n} f(\{s_i\}) &= \sum_{i=1}^{n} \left[m(s_i) + \frac{1}{n} \times m(\Omega) \right] \\
&= \sum_{i=1}^{n} m(\{s_i\}) + m(\Omega) = 1.
\end{aligned}
\tag{95}
$$

(2) 对任何 $A \subset \Omega$, 有 $\mathrm{Bel}(A) \leq f(A) \leq P_l(A)$.

$$\begin{aligned} &\because P_l(A) - P_l(B) = m(\Omega), \quad \frac{|A|}{|\Omega|} \geq 0 \\ &\therefore \mathrm{Bel}(A) \leq f(A) \\ &\quad \because \frac{|A|}{|\Omega|} \leq 1, f(A) \leq \mathrm{Bel}(A) + \mathrm{Pl}(A) - \mathrm{Bel}(A), \\ &\therefore f(A) \leq P_l(A). \end{aligned} \tag{96}$$

(3) 对任何 $A \subseteq \Omega$, 有 $f(\neg A) = 1 - f(A)$.

证据理论的推理模型

$$\because f(\neg A) = Bel(\neg A) + \frac{|A|}{|P_l(\neg A) - Bel(\neg A)|} \tag{97}$$

$$Bel(\neg A) = \sum_{\substack{s\in -A \\ s\in A|}} m(\{s_i\})$$

$$= 1 - \sum_{\substack{s_i\in A \\ s_i d}} m(\{s_i\}) - m(\Omega) = 1 - Bel(A) - m(\Omega). \tag{98}$$

$$|\neg A| = |\Omega| - |A|. \tag{99}$$

$$P_l(\neg A) - Bel(\neg A) = m(\Omega). \tag{100}$$

$$
\begin{aligned}
\therefore f(\neg A) &= 1 - \mathrm{Bel}(A) - m(\Omega) + \frac{|\Omega| - |A|}{|\Omega|} \times m(\Omega) \\
&= 1 - \mathrm{Bel}(A) - m(\Omega) + m(\Omega) - \frac{|A|}{|\Omega|} \times m(\Omega) \\
&= 1 - \left[\mathrm{Bel}(A) + \frac{|A|}{|\Omega|} \times m(\Omega)\right] = 1 - f(A).
\end{aligned} \tag{101}
$$

推论

(1) $f(\emptyset) = 0$;
(2) $f(\Omega) = 1$;
(3) 对任何 $A \subseteq \Omega$, 有 $0 \le f(A) \le 1$.

Example

设 $\Omega = \{红, 黄, 白\}$, 概率分配函数

$$m(\{\}, \{红\}, \{黄\}, \{白\}, \{红, 黄, 白\}) = (0, 0.6, 0.2, 0.1, 0.1). \tag{102}$$

若 $A = \{红, 黄\}$, 求 $f(A)$ 的值.

$$
\begin{aligned}
\mathsf{f}(\mathsf{A}) &= \mathsf{Bel}(\mathsf{A}) + \frac{|\mathsf{A}|}{|\Omega|} \times [\mathsf{P}_{\mathsf{l}}(\mathsf{A}) - \mathsf{Bel}(\mathsf{A})] \\
&= \mathsf{m}(\{\underline{\mathsf{l}}\}) + \mathsf{m}(\{\#\}) + \frac{2}{3} \times \mathsf{m}(\{\underline{\mathsf{L}}\mathbb{I}, \#, |\#, \quad \}) \\
&= 0.6 + 0.2 + \frac{2}{3} \times 0.1 = 0.87.
\end{aligned}
\tag{103}
$$

表示形式

$$\text{IF } E \text{ THEN } H = h_1, h_2, \cdots, h_n \text{ CF} = \{c_1, c_2, \cdots, c_n\}. \tag{104}$$

其中: • E 为前提条件, 它既可以是简单条件, 也可以是用合取或析取词连接起来的复合条件;
• H 是结论, 它用样本空间中的子集表示, $h_1, h_2, \cdots, h_n$ 是该子集中的元素;
• CF 是可信度因子, 用集合形式表示. 该集合中的元素 $c_1, c_2, \cdots, c_n$ 用来指出 $h_1, h_2, \cdots, h_n$ 的可信度, c_i 与 h_i 一一对应. 并且 c_i 应满足如下条件:

$$c_i \geq 0, \sum_{i=1}^{n} c_i \leq 1, i = 1, 2, \cdots, n. \tag{105}$$

Example

设 A 是规则条件部分的命题, E′ 是外部输入的证据和已证实的命题, 在证据 E′ 的条件下, 命题 A 与证据 E′ 的匹配程度为

$$\mathrm{MD}\left(A|E'\right) = \begin{cases} 1 \\ 0 \end{cases} \tag{106}$$

条件部分命题 A 的确定性

$$\mathrm{CER}(\mathrm{A}) = \mathrm{MD}(\mathrm{A}|\mathrm{E}') \times \mathrm{f}(\mathrm{A}), \tag{107}$$

其中 $\mathrm{f}(\mathrm{A})$ 为类概率函数. 由于 $\mathrm{f}(\mathrm{A}) \in [0,1]$, 因此 $\mathrm{CER}(\mathrm{A}) \in [0,1]$.

当组合证据是多个证据的合取时:

$$E = E_1 \text{ AND } E_2 \text{ AND} \cdots \text{AND } E_n. \tag{108}$$

则

$$CER(E) = \min\{CER(E_1), CER(E_2), \cdots, CER(E_n)\}. \tag{109}$$

当组合证据是多个证据的析取时:

$$E = E_1 \text{ OR } E_2 \text{ OR } \cdots \text{ OR } E_n. \tag{110}$$

则

$$CER(E) = \max\{CER(E_1), CER(E_2), \cdots, CER(E_n)\}. \tag{111}$$

设有知识 IF E THEN H $=\{h_1, h_2, \cdots, h_n\}$ CF $=\{c_1, c_2, \cdots, c_n\}$, 则求结论 H 的确定性 CER(H) 的方法如下: (1) 求 H 的概率分配函数

$$m(\{h_1\}, \{h_2\}, \ldots, \{h_3\}) = (CER(E) \times c_1, CER(E) \times c_2, \cdots, CER(E) \times c_n) \tag{112}$$

$$m(\Omega) = 1 - \sum_{i=1}^{n} CRE(E) \times c_i. \tag{113}$$

如果有两条或多条知识支持同一结论 H, 例:

$$\text{IF E THEN H} = \{h_1, h_2, \cdots, h_n\} \ \text{CF} = \{c_{11}, c_{12}, \cdots, c_{1n}\} \tag{114}$$

$$\text{IF F THEN H} = \{h_1, h_2, \cdots, h_n\} \ \text{CF} = \{c_{21}, c_{22}, \cdots, c_{2n}\}. \tag{115}$$

则按正交和求 CER(H), 即先求出:

$$m_1 = m(h_1, h_2, \cdots, h_n) \tag{116}$$

$$m_2 = m(h_1, h_2, \cdots, h_n). \tag{117}$$

然后再用公式 $m = m_1 \oplus m_2$ 求 m_1 和 m_2 的正交和, 最后求得 H 的 m.

(2) 求 Bel(H)、$P_l(H)$ 及 f(H)

$$\begin{aligned} \mathrm{Bel}(H) &= \sum_{i=1}^{n} m(\{h_i\}), \\ P_l(H) &= 1 - \mathrm{Bel}(\neg H), \\ f(H) &= \mathrm{Be}(H) + \frac{|H|}{|\Omega|} \times [P_l(H) - \mathrm{Be}(H)] = \mathrm{Be}(H) + \frac{|H|}{|\Omega|} \times m(\Omega). \end{aligned} \tag{118}$$

(3) 求 H 的确定性 CER(H)

按公式 $\mathrm{CER}(H) = \mathrm{MD}(H|E') \times f(H)$ 计算结论 H 确定性.

Example

设有如下规则:

- r_1: IF E1 AND E2 THEN A={a1, a2} CF={0.3, 0.5},
- r_2: IF E3 AND (E4 OR E5) THEN B={b1} CF={0.7},
- r_3: IF A THEN H={h1, h2, h3} CF={0.1, 0.5, 0.3},
- r_4: IF B THEN H={h1, h2, h3} CF={0.4, 0.2, 0.1}.

已知用户对初始证据给出的确定性为:

$$CER(E_1)=0.8,\ CER(E_2)=0.6,\ CER(E_3)=0.9,\ CER(E_4)=0.5,\ CER(E_5)=0.7.$$

并假定 Ω 中的元素个数 $\Omega = 10$, 求 CER(H).

由给定知识形成的推理网络为:

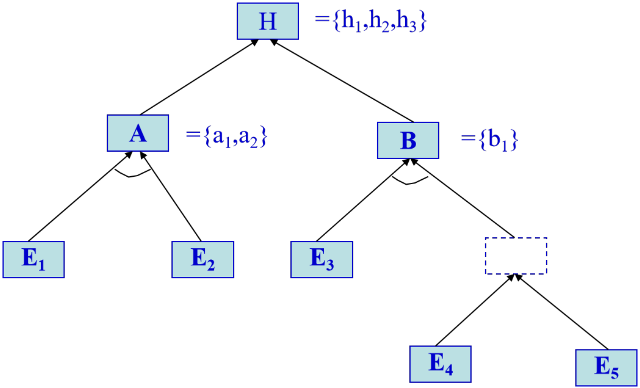

图 1: 给定知识形成的推理网络

(1) 求 CER(A)

$$\begin{aligned}
\because \mathrm{CER}(E_1 \text{ AND } E_2) &= \min\{\mathrm{CER}(E_1), \mathrm{CER}(E_2)\} = \min\{0.8, 0.6\} = 0.6. \\
m(a_1, a_2) &= \{0.6 \times 0.3, 0.6 \times 0.5\} = \{0.18, 0.3\}. \\
\mathrm{Bel}(A) &= m(a_1) + m(a_2) = 0.18 + 0.3 = 0.48. \\
P_l(A) &= 1 - \mathrm{Bel}(\neg A) = 1 - 0 = 1. \\
f(A) &= \mathrm{Bel}(A) + |A|/|\Omega| * [P_l(A) - \mathrm{Bel}(A)] \\
&= 0.48 + 2/10 * [1 - 0.48] = 0.584. \\
\therefore \mathrm{CER}(A) &= \mathrm{MD}(A|E') \times f(A) = 0.584.
\end{aligned}$$

(2) 求 CER(B)

$$
\begin{aligned}
\because \mathrm{CER}(E_3 \text{ AND } (E_4 \text{ OR } E_5)) &= \min\{\mathrm{CER}(E_3), \max\{\mathrm{CER}(E_4), \mathrm{CER}(E_5)\}\} \\
&= \min\{0.9, \max\{0.5, 0.7\}\} \\
&= \min\{0.9, 0.7\} = 0.7. \\
m(b_1) &= 0.7 \times 0.7 = 0.49. \\
\mathrm{Bel}(B) &= m(b_1) = 0.49. \\
\mathrm{Pl}(B) &= 1 - \mathrm{Bel}(\neg B) = 1 - 0 = 1. \\
F(B) &= \mathrm{Bel}(B) + |B|/|\Omega| * [P_l(B) - \mathrm{Bel}(B)] \\
&= 0.49 + 1/10 * [1 - 0.49] = 0.541. \\
\therefore \mathrm{CER}(B) &= \mathrm{MD}(B|E') \times f(B) = 0.541.
\end{aligned}
$$

(3) 求 CER(H), 由 r_3 可得

$$
\begin{aligned}
m_1(h_1, h_2, h_3) &= \{CER(A) \times 0.1, CER(A) \times 0.5, CER(A) \times 0.3\} \\
&= \{0.584 \times 0.1, 0.584 \times 0.5, 0.584 \times 0.3\} \\
&= \{0.058, 0.292, 0.175\}.
\end{aligned}
$$

$$
\begin{aligned}
m_1(\Omega) &= 1 - [m_1(h_1) + m_1(h_2) + m_1(h_3)] \\
&= 1 - (0.058 + 0.292 + 0.175) = 0.475.
\end{aligned}
$$

再由 r_4 可得

$$
\begin{aligned}
m_2(h_1, h_2, h_3) &= CER(B) \times 0.4, CER(B) \times 0.2, CER(B) \times 0.1 \\
&= \{0.541 \times 0.4, 0.541 \times 0.2, 0.541 \times 0.1\} \\
&= \{0.216, 0.108, 0.054\}. \\
m_2(\Omega) &= 1 - [m_2(h_1) + m_2(h_2) + m_2(h_3)] \\
&= 1 - [0.216 + 0.108 + 0.054] = 0.622.
\end{aligned}
$$

求正交和 $m = m_1 \oplus m_2$

$$
\begin{aligned}
K = {} & m_1(\Omega) \times m_2(\Omega) + m_1(h1) \times m_2(h1) + m_1(h1) \times m_2(\Omega) + m_1(\Omega) \times m_2(h1) \\
& + m_1(h_2) \times m_2(h_2) + m_1(h_2) \times m_2(\Omega) + m_1(\Omega) \times m_2(h_2) \\
& + m_1(h_3) \times m_2(h_3) + m_1(h_3) \times m_2(\Omega) + m_1(\Omega) \times m_2(h_3) \\
= {} & 0.475 \times 0.622 + 0.058 \times 0.216 + 0.058 \times 0.622 + 0.475 \times 0.216 \\
& + 0.292 \times 0.108 + 0.292 \times 0.622 + 0.475 \times 0.108 \\
& + 0.175 \times 0.054 + 0.175 \times 0.622 + 0.475 \times 0.054 = 0.855.
\end{aligned}
$$

$$
\begin{aligned}
m(h_1) &= \frac{1}{K} \times [m_1(\{h_1\}) \times m_2(\{h_1\}) + m_1(\{h_1\}) \times m_2(\Omega) + m_1(\Omega) \times m_2(\{h_1\})] \\
&= \frac{1}{0.855} \times [0.058 \times 0.216 + 0.058 \times 0.622 + 0.475 \times 0.216].
\end{aligned}
$$

$$
\begin{aligned}
m(h_2) &= \frac{1}{K} \times [m_1(\{h_2\}) \times m_2(\{h_2\}) + m_1(\{h_2\}) \times m_2(\Omega) + m_1(\Omega) \times m_2(\{h_2\})] \\
&= \frac{1}{0.855} \times [0.292 \times 0.108 + 0.292 \times 0.622 + 0.475 \times 0.108] \\
&= 0.309.
\end{aligned}
$$

$$\begin{aligned}
\mathrm{m}(\mathrm{h}_3) &= \frac{1}{\mathrm{K}} \times [\mathrm{m}_1(\{\mathrm{h}_3\}) \times \mathrm{m}_2(\{\mathrm{h}_3\}) + \mathrm{m}_1(\{\mathrm{h}_3\}) \times \mathrm{m}_2(\Omega) + \mathrm{m}_1(\Omega) \times \mathrm{m}_2(\{\mathrm{h}_3\})] \\
&= \frac{1}{0.855} \times [0.175 \times 0.054 + 0.175 \times 0.622 + 0.475 \times 0.054] \\
&= 0.168.
\end{aligned}$$

$$\mathrm{m}(\Omega) = 1 - [\mathrm{m}(\mathrm{h}_1) + \mathrm{m}(\mathrm{h}_2) + \mathrm{m}(\mathrm{h}_3)] = 1 - (0.178 + 0.309 + 0.168) = 0.345.$$

$$\mathrm{Bel}(H) = m(h_1) + m(h_2) + m(h_3) = 0.178 + 0.309 + 0.168 = 0.655$$
$$P_l(H) = m(\Omega) + \mathrm{Bel}(H) = 0.345 + 0.655 = 1.$$

$$\begin{aligned} f(H) &= \mathrm{Bel}(H) + \frac{|H|}{|\Omega|} \times [P_l(H) - \mathrm{Bel}(H)] \\ &= 0.655 + \frac{3}{10} \times [1 - 0.6555] \\ &= 0.759. \end{aligned}$$

$$\mathrm{CER}(H) = \mathrm{MD}(H|E') \times f(H) = 0.759.$$

DS 理论的优缺点

优点

能处理由“不知道”所引起的非精确性; 并且由于辨别框 (样本空间) 的子集可以是多个元素的集合, 这样更有利于领域专家在不同层次上进行知识表示.

缺点

要求辨别框中的元素满足互斥条件, 这在实际系统中不易实现; 并且, 需要给出的概率分配数太多, 计算比较复杂.

模糊推理表示

用自然语言中的词或句子表示的变量

Example

变量“年龄”在普通集合中为数字变量 $u = [0, 150]$, 而在模糊集和中可使用语言变量, 该语言变量的取值可以是年轻、很年轻、不很年轻、老、很老、不很老等. 这些值可看作是论域 $U = [0, 150]$ 上模糊集的集合名.

模糊谓词

模糊谓词

设 $x \in U$, F 为模糊谓词, 即 U 中的一个模糊关系, 则模糊命题可表示为

$$x \text{ is } F, \tag{119}$$

其中的模糊谓词 F 可以是大、小、年轻、年老、冷、暖、长、短等.

模糊量词

模糊量词

模糊逻辑中使用的模糊量词, 如极少、很少、几个、少数、多数、大多数、几乎所有等. 这些模糊量词可以很方便地描述类似于下面的命题:

- 大多数成绩好的学生学习都很刻苦.
- 很少有成绩好的学生特别贪玩.

模糊概率、模糊可能性和模糊真值

设 λ 为模糊概率, $\prod$ 为模糊可能性, τ 为模糊真值, 则对命题还可以附加概率限定、可能性限定和真值限定:

$$(\text{x is F}) \text{ is } \lambda (\text{x is F}) \text{ is } \prod (\text{x is F}) \text{ is } \tau, \tag{120}$$

其中, λ 可以是 "或许"、"必须" 等; π 可以是 "非常可能"、"很不可能" 等; τ 可以是 "非常真"、"有些假" 等.

Example

“常青很可能是年轻的”可表示为

(Age(Chang qing) is young) is likely.

模糊修饰语的表达

模糊修饰语

设 m 是模糊修饰语, x 是变量, F 谓模糊谓词, 则模糊命题可表示为 x is m_F, 模糊修饰语也称为程度词, 常用的程度词有 “很”、“非常”、“有些”、“绝对” 等.

主要通过以下四种运算实现

① 求补: ¬ 表示否定, 如 “不”、“非” 等, 其隶属函数的表示为

$$\mu_{\neg F}(u) = 1 - \mu_F(u) \quad u \in [0,1].$$

② 集中表示“很”、“非常”等，其效果是减少隶属函数的值：

$$\mu_{\text{非常F}}(\mathsf{u}) = \mu_{\mathsf{F}}^{2}(\mathsf{u}) \quad \mathsf{u} \in [0,1].$$

③ 扩张表示“有些”、“稍微”等，其效果是增加隶属函数的值：

$$\mu_{\text{有些F}}(\mathsf{u}) = \mu_{\mathsf{F}}^{\frac{1}{2}}(\mathsf{u}) \quad \mathsf{u} \in [0,1].$$

④ 加强对比表示"明确"、"确定"等, 其效果是增加 0.5 以上隶属函数的值, 减少 0.5 以下隶属函数的值:

$$\mu_{\text{确实F}}(\mathsf{u}) = \begin{cases} 2\mu_{\mathsf{F}}^2(\mathsf{u}), & 0 \le \mu_{\mathsf{F}}(\mathsf{u}) \le 0.5 \\ 1 - 2\left(1 - \mu_{\mathsf{F}}(\mathsf{u})\right)^2, & 0.5 < \mu_{\mathsf{F}}(\mathsf{u}) \le 1 \end{cases} .$$

在以上 4 种运算中, 集中与扩张用的较多.

语言变量“真实性”取值“真”和“假”的隶属函数

$$\mu_{真}(u) = u, u \in [0,1]$$
$$\mu_{假}(u) = 1 - u, u \in [0,1].$$

则“非常真”、“有些真”、“非常假”、“有些假”可定义为

$$\mu_{非常真}(u) = u^2, u \in [0,1]; \mu_{非常假}(u) = \mathbb{R} \qquad (u) = (1-u)^2, u \in [0,1] \tag{121}$$

$$\mu_{有些真}(u) = u^{\frac{1}{2}}, u \in [0,1]; \mu_{有些假}(u) = \pm \lim_{\mathbb{R}} \qquad (u) = (1-u)^{\frac{1}{2}}, u \in [0,1]. \tag{122}$$

扎德推理模型——产生式规则的表示形式是

IF x is F THEN y is G.

其中: x 和 y 是变量, 表示对象; F 和 G 分别是论域 U 和 V 上的模糊集, 表示概念.

语义距离

用于刻划两个模糊概念之间的差异. 一般使用的距离是海明距离.

离散论域: 设 $U = u_1, u_2, \cdots, u_n$ 是一个离散有限论域, F 和 G 分别是论域 U 上的两个模糊概念的模糊集, 则 F 和 G 的海明距离定义为

$$d(F, G) = \frac{1}{n} \times \sum_{i=1}^{n} \left|\mu_F(u_i) - \mu_G(u_i)\right|. \tag{123}$$

连续论域

如果论域 U 是实数域上的某个闭区间 $[a, b]$, 则海明距离为

$$d(F, G) = \frac{1}{b-a}\int_a^b |\mu_F(u) - \mu_G(u)|\, d(u). \tag{124}$$

Example

设论域 U $= \{-10, 0, 10, 20, 30\}$ 表示温度, 模糊集

$$\mathsf{F} = 0.8/-10 + 0.5/0 + 0.1/10, \tag{125}$$

$$\mathsf{G} = 0.9/-10 + 0.6/0 + 0.2/10. \tag{126}$$

分别表示“冷”和“比较冷”，则

$$\mathsf{d}(\mathsf{F}, \mathsf{G}) = 0.2 \times (|0.8 - 0.9| + |0.5 - 0.6| + |0.1 - 0.2|) = 0.2 \times 0.3 = 0.06. \tag{127}$$

即 F 和 G 的海明距离为 0.06.

设 F 和 G 分别是论域 $U = \{u_1, u_2, \cdots, u_n\}$ 上的两个模糊概念的模糊集, 则它们的贴近度定义为

$$(F, G) = (1/2)(F \cdot G + (1 - F \odot G)), \tag{128}$$

其中:

$$\begin{aligned} F \cdot G &= \vee \left(\mu_F\left(u_i\right) \wedge \mu_G\left(u_i\right)\right), \\ F \odot G &= \bigwedge\nolimits_U \left(\mu_F\left(u_i\right) \vee \mu_G\left(u_i\right)\right). \end{aligned} \tag{129}$$

称 $F \cdot G$ 为内积, $F \odot G$ 为外积.

Example

设论域 U 及其上的模糊集 F 和 G 如上例所示, 则

$$
\begin{aligned}
F \cdot G &= 0.8 \wedge 0.9 \vee 0.5 \wedge 0.6 \vee 0.1 \wedge 0.2 \vee 0 \wedge 0 \vee 0 \wedge 0 \\
&= 0.8 \vee 0.5 \vee 0.1 \vee 0 \vee 0 = 0.8 \\
F \odot G &= (0.8 \vee 0.9) \wedge (0.5 \vee 0.6) \wedge (0.1 \vee 0.2) \wedge (0 \vee 0) \wedge (0 \vee 0) \\
&= 0.9 \wedge 0.6 \wedge 0.2 \wedge 0 \wedge 0 = 0 \\
(F, G) &= 0.5 \times (0.8 + (1 - 0)) = 0.5 \times 1.8 = 0.9.
\end{aligned}
$$

即 F 和 G 的贴近度为 0.9.

模糊推理及其构造

模糊推理实际上是按照给定的推理模式, 通过模糊集合与模糊关系的合成来实现的.

模糊关系 R_m

R_m 是由扎德提出的一种构造模糊关系的方法. 设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_m 定义为

$$R_m = \int_{U\times V} (\mu_F(u) \wedge \mu_G(v)) \vee (1 - \mu_F(u)) /(u, v), \tag{130}$$

其中, $\times$ 号表示模糊集的笛卡尔乘积.

Example

设 $\mathsf{U} = \mathsf{V} = \{1, 2, 3\}$, F 和 G 分别是 U 和 V 上的两个模糊集, 且 $\mathsf{F} = 1/1 + 0.6/2 + 0.1/3$, $\mathsf{G} = 0.1/1 + 0.6/2 + 1/3$, 求 $\mathsf{U} \times \mathsf{V}$ 上的 $\mathsf{R_m}$.

$$\mathsf{R_m} = \int_{\mathsf{U}\times\mathsf{V}} (\mu_{\mathsf{F}}(\mathsf{u}) \wedge \mu_{\mathsf{G}}(\mathsf{v})) \vee (1 - \mu_{\mathsf{F}}(\mathsf{u})) \,/(\mathsf{u}, \mathsf{v}).$$

$$\mathsf{R_m} = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.4 & 0.6 & 0.6 \\ 0.9 & 0.9 & 0.9 \end{bmatrix}.$$

如: $\mathsf{R_m}(2, 3) = (0.6 \wedge 1) \vee (1 - 0.6) = 0.6 \vee 0.4 = 0.6.$

模糊关系 R_c

R_c 是由麦姆德尼 (Mamdani) 提出的一种构造模糊关系的方法.

设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_c 义为

$$R_c = \int_{U \times V} (\mu_F(u) \wedge \mu_G(v))_{\mathcal{Q}} / (u, v).$$

Example

对例 26 所给出的模糊集

$$\mathsf{F} = 1/1 + 0.6/2 + 0.1/3, \mathsf{G} = 0.1/1 + 0.6/2 + 1/3.$$

其 $\mathsf{R_c}$ 为

$$\mathsf{R_c} = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix},$$

如 $\mathsf{R_c}(3,2)$: $\mathsf{R_c}(3,2) = \mu_{\mathsf{F}}(\mathsf{u}_3) \wedge \mu_{\mathsf{G}}(\mathsf{v}_2) = 0.1 \wedge 0.6 = 0.1.$

模糊关系 R_g

R_g 是米祖莫托 (Mizumoto) 提出的一种构造模糊关系的方法.

设 F 和 G 分别是论域 U 和 V 上的两个模糊集, 则 R_g 定义为

$$R_g = \int_{U\times V} \left(\mu_F(u) \to \mu_G(v)\right) / (u, v),$$

其中

$$\mu_F(u) \to \mu_G(v) = \begin{cases} 1, & \mu_F = \mu_F(u) \le \mu_G(v)^{\top} \\ \mu_F(v), & \mu_F(u) > \mu_G(v)^{\top}. \end{cases} .$$

Example

对例 26 所给出的模糊集

$$\mathsf{F} = 1/1 + 0.6/2 + 0.1/3,\ \mathsf{G} = 0.1/1 + 0.6/2 + 1/3.$$

其 $\mathsf{R_g}$ 为

$$\mathsf{R_g} = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

模糊假言推理

设 F 和 G 分别是 U 和 V 上的两个模糊集, 且有知识

知识： IF x is F THEN y is G.

若有 U 上的一个模糊集 F′, 且 F 可以和 F′ 匹配, 则可以推出 y is G′, 且 G′ 是 V 上的一个模糊集. 这种推理模式称为模糊假言推理, 其表示形式为:

知识： IF x is F THEN y is G

证据： IF x is F′

— — — — — — — — — — — — — —

结论： THEN y is G′

在这种推理模式下, 模糊知识

$$\text{IF } x \text{ is } F \text{ THEN } y \text{ is } G.$$

表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R. 则有

$$G' = F' \circ R,$$

其中的模糊关系 R, 可以是 R_m、R_c 或 R_g 中的任何一种.

模糊推理的基本方法

Example

对例 26 所给出的 F、G, 以及所求出的 R_m, 设有已知事实: $\{x \text{ is 较小}\}$, 并设 “较小” 的模糊集为: 较小 $= 1/1 + 0.7/2 + 0.2/3$, 求在此已知事实下的模糊结论.

例 26 的模糊关系 R_m 已在例 26 中求出, 设已知模糊事实 “较小” 为 F', F' 与 R_m 的合成即为所求结论 G'.

$$G' = F' \circ R_m = \{1, 0.7, 0.2\} \circ \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.4 & 0.6 & 0.6 \\ 0.9 & 0.9 & 0.9 \end{bmatrix} = \{0.4, 0.6, 1\}.$$

即所求出的模糊结论 G' 为 $G' = 0.4/1 + 0.6/2 + 1/3$.

模糊拒取式推理

设 F 和 G 分别是 U 和 V 上的两个模糊集, 且有知识

$$\text{IF } x \text{ is } F \text{ THEN } y \text{ is } G.$$

若有 V 上的一个模糊集 G′, 且 G 可以和 G′ 匹配, 则可以推出 x is F′, 且 F′ 是 U 上的一个模糊集.

模糊拒取式推理

其表示形式为:

$$
\begin{array}{ll}
\text{知识：} & \text{IF } x \text{ is } F \text{ THEN } y \text{ is } G. \\
\text{证据：} & \qquad\qquad\quad \text{THEN } z \text{ is } H. \\
\hline
\text{结论：} & \text{IF } x \text{ is } F'.
\end{array}
$$

在这种推理模式下, 模糊知识

$$\text{IF } x \text{ is } F \text{ THEN } y \text{ is } G.$$

也表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R, 则有 $F' = R \circ G'$, 其中的模糊关系 R, 可以是 R_m、R_c 或 R_g 中的任何一种.

Example

设 F 和 G 如例 26 所示, 已知事实为 $\{y$ is 较大$\}$, 且 "较大" 的模糊集为: 较大 $= 0.2/1 + 0.7/2 + 1/3$, 若已知事实与 G 匹配, 以模糊关系 R_c 为例, 在此已知事实下可以推出 F'.

本例的模糊关系 R_c 已在前面求出, 设模糊概念 "较大" 为 G', 则 R_c 与 G' 的合成即为所求的 F'.

$$F' = R_c \circ G' = \begin{bmatrix} 0.1 & 0.6 & 1 \\ 0.1 & 0.6 & 0.6 \\ 0.1 & 0.1 & 0.1 \end{bmatrix} \circ \begin{bmatrix} 0.2 \\ 0.7 \\ 1 \end{bmatrix} = \begin{bmatrix} 1 \\ 0.6 \\ 0.1 \end{bmatrix}.$$

即所求出的 F' 为 $G' = 1/1 + 0.6/2 + 0.1/3$.

模糊假言三段论推理

设 F, G, H 分别是 U, V, W 上的 3 个模糊集, 且由知识

IF x is F THEN y is G,
IF y is G THEN z is H.

则可推出:

IF x is F THEN z is H.

模糊假言三段论推理

它可表示为:

IF x is F THEN y is G
IF y is G THEN z is H
— — — — — — — — — — — —
IF x is F THEN z is H.

在模糊假言三段论推理模式下, 模糊知识

r_1 : IF x is F THEN y is G,

表示在 F 与 G 之间存在着确定的因果关系, 设此因果关系为 R_1.

模糊知识

$$r_2 : \text{IF } y \text{ is } G \text{ THEN } z \text{ is } H,$$

表示在 G 与 H 之间存在着确定的因果关系, 设此因果关系为 R_2.

若模糊假言三段论成立, 则模糊结论

$$r_3 : \text{IF } x \text{ is } F \text{ THEN } z \text{ is } H$$

的模糊关系 R_3 可由 R_1 与 R_2 的合成得到. 即

$$R_3 = R_1 \circ R_2,$$

这里的关系 R_1、R_2 和 R_3 都可以是前面所讨论过的 R_m、R_c、R_g 中的任何一种.

Example

设 $U = W = V = 1, 2, 3$, $E = 1/1 + 0.6/2 + 0.2/3$,
$F = 0.8/1 + 0.5 + 0.1/3$, $G = 0.2/1 + 0.6 + 1/3$. 按 R_g 求 $E \times F \times G$ 上的关系 R.

先求 $E \times F$ 上的关系 R_1

$$R_1 = \begin{bmatrix} 0.8 & 0.5 & 0.1 \\ 1 & 0.5 & 0.1 \\ 1 & 1 & 0.1 \end{bmatrix}.$$

再求 $E \times G$ 上的关系 R_2:

$$R_2 = \begin{bmatrix} 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \\ 1 & 1 & 1 \end{bmatrix}.$$

最后求 $E \times F \times G$ 上的关系 R,

$$R = R_1 \circ R_2 = \begin{bmatrix} 0.2 & 0.6 & 0.8 \\ 0.2 & 0.6 & 1 \\ 0.2 & 1 & 1 \end{bmatrix}.$$